

Tarea_1_Alvear_Benjamin

April 28, 2026

```
[1]: import polars as pl
import pandas as pd
import numpy as np
import missingno as msno
import matplotlib.pyplot as plt
import statsmodels.api as sm
```

0.0.1 1. Carga y Exploración Inicial de los Datos

Para comenzar, cargamos la base de datos `student_productivity.csv` al ambiente de trabajo. Utilizamos los métodos `.info()` y `.describe()` para realizar un análisis exploratorio inicial (EDA). Esto nos permite identificar los **tipos de datos** de cada variable (numéricas vs. categóricas), observar las estadísticas descriptivas básicas, y detectar a simple vista irregularidades como **valores nulos** (missing values) y posibles **valores atípicos** (outliers) en las distribuciones.

```
[2]: df = pd.read_csv(
    "data\student_productivity.csv"
)
```

```
[3]: df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 5621 entries, 0 to 5620
Data columns (total 22 columns):
#   Column              Non-Null Count  Dtype
---  -
0   student_id          5621 non-null   int64
1   age                 4973 non-null   float64
2   gender              5063 non-null   str
3   academic_level      4991 non-null   str
4   study_hours         5047 non-null   float64
5   self_study_hours    4954 non-null   float64
6   online_classes_hours 4939 non-null   float64
7   social_media_hours   4965 non-null   float64
8   gaming_hours        4965 non-null   float64
9   sleep_hours         5068 non-null   float64
10  screen_time_hours    5035 non-null   float64
```

```

11 exercise_minutes      5022 non-null    str
12 caffeine_intake_mg    5021 non-null    float64
13 part_time_job         4918 non-null    str
14 upcoming_deadline     4904 non-null    float64
15 internet_quality      5098 non-null    str
16 mental_health_score   4946 non-null    float64
17 drug_use              1518 non-null    float64
18 focus_index           4988 non-null    float64
19 burnout_level         4905 non-null    float64
20 productivity_score     4983 non-null    float64
21 exam_score            4912 non-null    float64

```

dtypes: float64(16), int64(1), str(5)

memory usage: 1.1 MB

```
[4]: df.describe()
```

```

[4]:      student_id      age  study_hours  self_study_hours \
count  5621.000000  4973.000000  5047.000000      4954.000000
mean    2811.000000    20.510557    4.538708        2.480454
std     1622.787263    2.876399    1.819412        1.178094
min       1.000000    16.000000    0.000000        0.000000
25%     1406.000000    18.000000    3.260000        1.660000
50%     2811.000000    20.000000    4.530000        2.480000
75%     4216.000000    23.000000    5.760000        3.280000
max     5621.000000    25.000000   11.840000        7.410000

      online_classes_hours  social_media_hours  gaming_hours  sleep_hours \
count          4939.000000          4965.000000   4965.000000   5068.000000
mean             2.012296             3.002872     1.571458     7.023301
std             0.983104             1.472740     1.112557     1.159948
min             0.000000             0.000000     0.000000     4.000000
25%             1.320000             2.000000     0.680000     6.250000
50%             2.010000             2.990000     1.500000     7.015000
75%             2.690000             4.030000     2.350000     7.820000
max             6.000000             8.280000     5.640000    10.000000

      screen_time_hours  caffeine_intake_mg  upcoming_deadline \
count          5035.000000          5021.000000      4904.000000
mean             6.979045            250.804820        0.501223
std             2.482912            143.685652        0.500049
min             1.000000             0.000000        0.000000
25%             5.280000            129.000000        0.000000
50%             6.950000            251.000000        1.000000
75%             8.705000            375.000000        1.000000
max            15.300000            499.000000        1.000000

```

```

      mental_health_score  drug_use  focus_index  burnout_level \

```

count	4946.000000	1518.000000	4988.000000	4905.000000
mean	5.516983	0.661397	29.388119	45.633156
std	2.873859	0.473391	9.996024	14.257283
min	1.000000	0.000000	1.000000	1.000000
25%	3.000000	0.000000	22.460000	35.770000
50%	5.000000	1.000000	29.380000	45.650000
75%	8.000000	1.000000	36.232500	55.410000
max	10.000000	1.000000	63.480000	97.580000

	productivity_score	exam_score
count	4983.000000	4912.000000
mean	37.313526	18.840542
std	16.841997	12.119456
min	1.000000	1.000000
25%	25.330000	9.410000
50%	36.920000	17.990000
75%	49.200000	27.410000
max	98.020000	64.090000

0.0.2 2. Limpieza de Datos: Eliminación de variables no informativas

Al revisar la información del dataset, se hace evidente que la variable `drug_use` contiene una inmensa cantidad de valores nulos (la gran mayoría de la muestra). Dado que carece de suficientes datos reportados para ser estadísticamente significativa en un modelo, se toma la decisión de **eliminar esta columna** completamente (`drop`) para evitar ruido o distorsiones en los análisis posteriores.

```
[5]: df = df.drop(columns=['drug_use'])
```

0.0.3 3. Limpieza y Procesamiento de la variable `academic_level`

La variable categórica `academic_level` presentaba dos problemas: espacios en blanco residuales y valores nulos. 1. Se limpiaron los *strings* (usando `.str.strip()`) para unificar las categorías correctamente. 2. Los valores faltantes se imputaron utilizando la **moda** (el valor más frecuente), lo cual es la técnica estándar y más robusta para mantener la distribución en variables categóricas. 3. Finalmente, se mapearon las categorías a valores numéricos enteros para que puedan ser procesados matemáticamente por los modelos de regresión.

```
[6]: # 1. Verificamos cómo están los datos originalmente
print("Categorías originales:", df['academic_level'].unique())

# 2. Eliminamos los espacios en blanco al inicio y al final del texto
df['academic_level'] = df['academic_level'].str.strip()
print("Categorías sin espacios:", df['academic_level'].unique())

# 3. Rellenamos los valores nulos (nan) con la moda (el nivel más común)
```

```
df['academic_level'] = df['academic_level'].fillna(df['academic_level'].
    ↪mode()[0])
df['academic_level'] = df['academic_level'].map({'High School': 1,
    ↪'Undergraduate': 2, 'Postgraduate': 3})

# Comprobamos el resultado final
print("Niveles académicos convertidos a números:", df['academic_level'].unique())
```

```
Categorías originales: <ArrowStringArray>
[ 'Undergraduate',      'High School', 'Undergraduate ',      'Postgraduate',
      nan,      'High School ',      'Postgraduate ']
Length: 7, dtype: str
Categorías sin espacios: <ArrowStringArray>
['Undergraduate', 'High School', 'Postgraduate', nan]
Length: 4, dtype: str

Niveles académicos convertidos a números: [2 1 3]
```

0.0.4 4. Manejo de Valores Atípicos (Outliers) en study_hours

Un análisis visual mediante un *boxplot* nos permitió confirmar la presencia de valores atípicos (outliers) en la variable `study_hours`.

Para corregir esto sin perder observaciones valiosas (lo cual ocurriría si elimináramos las filas), se aplicó el método estadístico de **Rango Intercuartílico (IQR)** para identificar los bigotes de la distribución. Posteriormente, se utilizó la técnica de **Capping (acotamiento)** usando `.clip()`, imponiendo un límite inferior de cero (para evitar horas negativas) y un límite superior basado en el cálculo de $Q3 + 1.5 * IQR$. Esto asegura que los valores se mantengan dentro de un rango realista sin distorsionar la media.


```
[7]: import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")

# Crear una figura con dos subgráficos
plt.figure(figsize=(14, 5))

# 2. Boxplot (Diagrama de caja)
plt.subplot(1, 2, 2)
sns.boxplot(x=df['study_hours'].dropna(), color='#FFB347')
plt.title('Detección de Outliers en Horas de Estudio', fontsize=14)
plt.xlabel('Horas de Estudio Diarias', fontsize=12)

plt.tight_layout()
plt.show()
```



```
[8]: # 1. Calcular el Q1 y Q3
Q1 = df['study_hours'].quantile(0.25)
Q3 = df['study_hours'].quantile(0.75)

# 2. Calcular el Rango Intercuartílico (IQR)
IQR = Q3 - Q1

# 3. Definir el Límite Superior (y el inferior, asegurando que no baje de 0)
limite_superior = Q3 + 1.5 * IQR
limite_inferior = max(0, Q1 - 1.5 * IQR)

print(f"El límite superior calculado es: {limite_superior:.2f} horas.")

# 4. Aplicar el Capping usando la función .clip()
df['study_hours'] = df['study_hours'].clip(lower=limite_inferior,
    ↳upper=limite_superior)

print(";Outliers topados exitosamente!")
```

El límite superior calculado es: 9.51 horas.
 ;Outliers topados exitosamente!

0.0.5 5. Generación de Variable Binaria Target (rindio_examen)

Las instrucciones indican que un puntaje de 1.0 en `exam_score` señala a un estudiante que no rindió el examen. Para preparar nuestra variable dependiente (target) para los modelos de probabilidad lineal, Logit y Probit, creamos la variable binaria `rindio_examen`. Usando lógica vectorizada (`np.where`), asignamos un 1 a todo estudiante con puntaje estrictamente mayor a 1.0 (quienes sí rindieron) y un 0 al resto.

```
[9]: df['rindio_examen'] = np.where(df['exam_score'] > 1.0, 1, 0)
```

```
[10]: df.reset_index
```

```
[10]: <bound method DataFrame.reset_index of          student_id  age  gender
academic_level  study_hours  self_study_hours  \
0              1  20.0      NaN              2      5.37      2.09
1              2  16.0  Female              1      5.85      5.04
2              3  18.0  Female              2      5.69      2.27
3              4  24.0   Male              2      2.32      1.06
4              5  24.0  Female              3      3.87      2.63
...          ...    ...      ...          ...      ...      ...
5616          5617  21.0   Male              3      4.16      0.00
5617          5618  25.0  Female              3      NaN      NaN
5618          5619   NaN    NaN              3      NaN      NaN
5619          5620   NaN    NaN              3      NaN      NaN
5620          5621  18.0   Male              3      3.96      0.98
```

```
          online_classes_hours  social_media_hours  gaming_hours  sleep_hours  \
0              1.85              3.66              2.32              7.73
1              1.87              3.60              2.79              6.11
2              0.00              2.93              3.94              7.11
3              2.30              4.34              2.37              8.54
4              2.54              3.71              1.30              7.69
...          ...              ...              ...              ...
5616          1.27              4.01              3.41              8.07
5617          NaN              5.18              NaN              NaN
5618          NaN              NaN              NaN              NaN
5619          NaN              3.52              NaN              NaN
5620          1.77              4.35              2.22              6.57
```

```
          ...  caffeine_intake_mg  part_time_job  upcoming_deadline  \
0          ...              475.0              No              0.0
1          ...              362.0              no              0.0
2          ...              200.0              No              0.0
3          ...              233.0              No              1.0
4          ...              159.0              No              1.0
...          ...              ...              ...              ...
5616          ...              152.0              no              1.0
5617          ...              NaN              NaN              NaN
```

5618	...	NaN	Yes	NaN
5619	...	NaN	NaN	NaN
5620	...	154.0	No	0.0

	internet_quality	mental_health_score	focus_index	burnout_level	\
0	Good	3.0	19.01	31.77	
1	Good	10.0	42.10	45.89	
2	Average	5.0	21.93	37.07	
3	Poor	3.0	13.47	43.63	
4	Poor	2.0	19.95	56.62	
...	...	...	...	...	
5616	Poor	7.0	21.78	48.07	
5617	NaN	8.0	NaN	NaN	
5618	NaN	NaN	NaN	NaN	
5619	NaN	NaN	NaN	NaN	
5620	Poor	3.0	16.28	36.62	

	productivity_score	exam_score	rindio_examen
0	42.59	25.08	1
1	67.15	37.83	1
2	37.68	18.66	1
3	12.83	1.00	0
4	18.53	7.78	1
...	...	...	...
5616	43.06	17.15	1
5617	42.52	21.06	1
5618	NaN	NaN	0
5619	NaN	NaN	0
5620	21.36	2.81	1

[5621 rows x 22 columns]>

```
[11]: df.describe()
```

```
[11]:
```

	student_id	age	academic_level	study_hours	\
count	5621.000000	4973.000000	5621.000000	5047.000000	
mean	2811.000000	20.510557	2.116883	4.536323	
std	1622.787263	2.876399	0.834766	1.812142	
min	1.000000	16.000000	1.000000	0.000000	
25%	1406.000000	18.000000	1.000000	3.260000	
50%	2811.000000	20.000000	2.000000	4.530000	
75%	4216.000000	23.000000	3.000000	5.760000	
max	5621.000000	25.000000	3.000000	9.510000	

	self_study_hours	online_classes_hours	social_media_hours	\
count	4954.000000	4939.000000	4965.000000	
mean	2.480454	2.012296	3.002872	

std	1.178094	0.983104	1.472740
min	0.000000	0.000000	0.000000
25%	1.660000	1.320000	2.000000
50%	2.480000	2.010000	2.990000
75%	3.280000	2.690000	4.030000
max	7.410000	6.000000	8.280000


	gaming_hours	sleep_hours	screen_time_hours	caffeine_intake_mg \
count	4965.000000	5068.000000	5035.000000	5021.000000
mean	1.571458	7.023301	6.979045	250.804820
std	1.112557	1.159948	2.482912	143.685652
min	0.000000	4.000000	1.000000	0.000000
25%	0.680000	6.250000	5.280000	129.000000
50%	1.500000	7.015000	6.950000	251.000000
75%	2.350000	7.820000	8.705000	375.000000
max	5.640000	10.000000	15.300000	499.000000

	upcoming_deadline	mental_health_score	focus_index	burnout_level \
count	4904.000000	4946.000000	4988.000000	4905.000000
mean	0.501223	5.516983	29.388119	45.633156
std	0.500049	2.873859	9.996024	14.257283
min	0.000000	1.000000	1.000000	1.000000
25%	0.000000	3.000000	22.460000	35.770000
50%	1.000000	5.000000	29.380000	45.650000
75%	1.000000	8.000000	36.232500	55.410000
max	1.000000	10.000000	63.480000	97.580000

	productivity_score	exam_score	rindio_examen
count	4983.000000	4912.000000	5621.000000
mean	37.313526	18.840542	0.795766
std	16.841997	12.119456	0.403177
min	1.000000	1.000000	0.000000
25%	25.330000	9.410000	1.000000
50%	36.920000	17.990000	1.000000
75%	49.200000	27.410000	1.000000
max	98.020000	64.090000	1.000000

```
[12]: msno.matrix(df)
```

```
[12]: <Axes: >
```

0.0.6 7. Imputación de Valores Faltantes en Variables Numéricas

Para evitar la pérdida masiva de información, se ha decidido imputar los datos faltantes en las variables numéricas continuas y discretas. Se utilizó la **mediana** (median) en lugar de la media (mean) para variables como la edad, horas de sueño, horas de juego y niveles de estrés. Esta decisión se justifica debido a que la mediana es robusta y no se ve fuertemente afectada por la presencia de valores atípicos extremos (outliers) que suelen existir en métricas de tiempo o productividad.

```
[13]: ##### Variables Numéricas #####
df['study_hours'] = df['study_hours'].fillna(df['study_hours'].median())
df['self_study_hours'] = df['self_study_hours'].fillna(df['self_study_hours'].
    ↳median())
df['social_media_hours'] = df['social_media_hours'].
    ↳fillna(df['social_media_hours'].median())
df['gaming_hours'] = df['gaming_hours'].fillna(df['gaming_hours'].median())
df['sleep_hours'] = df['sleep_hours'].fillna(df['sleep_hours'].median())
df['screen_time_hours'] = df['screen_time_hours'].fillna(df['screen_time_hours'].
    ↳median())
df['online_classes_hours'] = df['online_classes_hours'].
    ↳fillna(df['online_classes_hours'].median())

df['age'] = df['age'].fillna(df['age'].median())
df['caffeine_intake_mg'] = df['caffeine_intake_mg'].
    ↳fillna(df['caffeine_intake_mg'].median())
df['mental_health_score'] = df['mental_health_score'].
    ↳fillna(df['mental_health_score'].median())
df['focus_index'] = df['focus_index'].fillna(df['focus_index'].median())
```

```
df['burnout_level'] = df['burnout_level'].fillna(df['burnout_level'].median())
df['productivity_score'] = df['productivity_score'].
    →fillna(df['productivity_score'].median())
```

0.0.7 8. Estandarización y Codificación de Variables Categóricas

Se procesaron tres variables categóricas clave siguiendo distintos enfoques según su naturaleza:

- * **Calidad de Internet (internet_quality):** Al ser una variable categórica ordinal (pobre < promedio < buena), estandarizamos el texto eliminando mayúsculas y espacios, imputamos los nulos con la moda, y finalmente la mapeamos a una escala numérica ordinal (1, 2, 3) que preserva su relación de jerarquía.
- * **Género (gender):** Tras limpiar y rellenar con la moda, aplicamos el método de variables *Dummy* (`pd.get_dummies`) para transformarla a valores numéricos. Se utilizó `drop_first=True` para generar solo la columna `gender_male`, evitando redundancia y previniendo el error estadístico de “multicolinealidad perfecta” crucial para modelos OLS.
- * **Examen inminente (upcoming_deadline):** Al ya estar expresada de manera binaria, simplemente cubrimos sus valores nulos con la moda.

```
[14]: ##### Variables Categóricas #####

#----- CALIDAD DE INTERNET -----#
# 1. Transformamos a minúsculas y limpiamos espacios para evitar errores de tipeo
df['internet_quality'] = df['internet_quality'].str.lower().str.strip()
# 2. Rellenamos nulos con la moda
moda_internet = df['internet_quality'].mode()[0]
df['internet_quality'] = df['internet_quality'].fillna(moda_internet)
# 3. Transformación a valores numéricos ORDINALES
df['internet_quality'] = df['internet_quality'].map({'poor': 1, 'average': 2,
    →'good': 3})
print("Formato final de internet_quality:")
print(df['internet_quality'].value_counts())

#----- GÉNERO -----#
# 1. Limpieza de texto
df['gender'] = df['gender'].str.lower().str.strip()

# 2. Rellenar nulos con la moda predominante
moda_genero = df['gender'].mode()[0]
df['gender'] = df['gender'].fillna(moda_genero)

# 3. Transformar a Dummies (Esto creará una nueva columna binaria)
# drop_first=True evita multicolinealidad perfecta (la famosa "trampa dummy") en
    →el OLS
df = pd.get_dummies(df, columns=['gender'], drop_first=True, dtype=int)

# Ahora existirá una columna llamada probablemente 'gender_male' con 1 y 0
print(";Conversión dummy exitosa! Generada la columna masculina/femenina.")
```

```
#----- EXAMEN PRONTO -----#
# 1. Rellenamos los nulos con la moda (ya es 0 y 1, por lo que usaremos la clase
    ↳mayoritaria)
moda_deadline = df['upcoming_deadline'].mode()[0]
df['upcoming_deadline'] = df['upcoming_deadline'].fillna(moda_deadline)

print("Nulos eliminados en upcoming_deadline.")
```

Formato final de internet_quality:

```
internet_quality
```

```
3    2269
```

```
2    1680
```

```
1    1672
```

```
Name: count, dtype: int64
```

¡Conversión dummy exitosa! Generada la columna masculina/femenina.

Nulos eliminados en upcoming_deadline.

0.0.8 9. Binarización de la variable part_time_job

Se repitió el proceso de limpieza de texto para unificar las respuestas a simplemente “yes” o “no”. Tras asegurar que no hubiese espacios ni mayúsculas que generaran categorías duplicadas, imputamos con la moda y transformamos directamente usando un diccionario manual (.map()) a valores binarios matemáticos: 1 para “sí” y 0 para “no”, dejándola lista para la regresión.

```
[15]: # 1. Uniformamos texto (convertimos todo a minúsculas y limpiamos espacios)
df['part_time_job'] = df['part_time_job'].str.lower().str.strip()

# Validamos que ahora sólo existan 'yes' o 'no' (o posibles nulos)
print("Categorías extrañas corregidas:", df['part_time_job'].unique())

# 2. Rellenamos datos faltantes (nulos) con la moda (que suele ser 'no')
if df['part_time_job'].isnull().sum() > 0:
    moda_trabajo = df['part_time_job'].mode()[0]
    df['part_time_job'] = df['part_time_job'].fillna(moda_trabajo)

# 3. Transformamos a binario (1 y 0) en la misma columna
df['part_time_job'] = df['part_time_job'].map({'yes': 1, 'no': 0})

print("Formato final de part_time_job:")
print(df['part_time_job'].value_counts())
```

Categorías extrañas corregidas: <ArrowStringArray>

```
['no', 'yes', nan]
```

```
Length: 3, dtype: str
```

Formato final de part_time_job:

```
part_time_job
```

```
0    3172
1    2449
Name: count, dtype: int64
```

0.0.9 10. Extracción de datos en columnas sucias (exercise_minutes)

Se utilizó una **Expresión Regular (Regex)** mediante la función `.str.extract(r'(\d+)')` para “capturar” únicamente los dígitos numéricos dentro del string, parseándolos a formato Flotante (numérico) y luego rellenando los vacíos con la mediana representativa.

```
[16]: # 1. Extraemos SOLO los números de la columna de texto (ignora letras como
      ↪ "mins")
df['exercise_minutes'] = df['exercise_minutes'].astype(str).str.extract(r'(\d+)')

# 2. Lo convertimos a número flotante (float) para poder operarlo matemáticamente
df['exercise_minutes'] = df['exercise_minutes'].astype(float)

# 3. Rellenamos posibles vacíos generados (si alguien escribió "nada") con la
      ↪ mediana
mediana_ejercicio = df['exercise_minutes'].median()
df['exercise_minutes'] = df['exercise_minutes'].fillna(mediana_ejercicio)

print(";Problema resuelto! exercise_minutes ahora es numérico.")
# Puedes comprobarlo haciendo: print(df['exercise_minutes'].dtype)

;Problema resuelto! exercise_minutes ahora es numérico.
```

0.0.10 11. Control de Calidad y Validación Lógica: Límite de las 24 Horas Diarias

Uno de los problemas lógicos más comunes en encuestas auto-reportadas sobre uso del tiempo, es que las personas pueden exagerar u omitir sumar correctamente, terminando en totales diarios que superan físicamente las 24 horas del día. Para auditar esto: 1. Calculamos la suma total de horas activas (restando factores que podrían ocurrir simultáneamente pero manteniendo el rubro principal: `study_hours`, `sleep_hours`, `social_media`, `gaming` y `exercise`). 2. Identificamos qué alumnos rompían la regla lógica sumando más de 24 horas. 3. Se aplicó una normalización. Modificamos el valor de dichas horas multiplicándolo por la proporción correcta (24/Suma de sus horas). De esta forma, castigamos el exceso pero mantenemos de manera realista la “proporción de tiempo” que la persona le dedicó a cada actividad en su día.

```
[17]: # 1. Definimos las columnas base de uso del tiempo (excluyendo las que se
      ↪ solapan)
columnas_horas = [
    'study_hours',
    'sleep_hours',
    'social_media_hours',
    'gaming_hours'
```

```

]

# (Opcional) Podemos incluir los minutos de ejercicio convirtiéndolos a horas
df['exercise_hours'] = df['exercise_minutes'] / 60.0
columnas_horas.append('exercise_hours')

# 2. Calculamos las horas totales de cada alumno
df['suma_horas'] = df[columnas_horas].sum(axis=1)

# Filtramos para observar cuántos tienen el error lógico
filtro_sobrepasan = df['suma_horas'] > 24.0
print(f"Alumnos que reportaron imposiblemente más de 24 hrs al día:
↳{filtro_sobrepasan.sum()}")

# 3. Solución (Proporción): Escalar las horas para que el máximo sea 24
for col in columnas_horas:
    # Fórmula: Valor nuevo = Valor antiguo * (24 / Suma de sus horas)
    df.loc[filtro_sobrepasan, col] = df.loc[filtro_sobrepasan, col] * (24.0 / df.
↳loc[filtro_sobrepasan, 'suma_horas'])

# Comprobamos el resultado (usamos > 24.01 por los decimales infinitos de Python)
df['suma_horas'] = df[columnas_horas].sum(axis=1)
print(f"Alumnos excedidos tras la limpieza: {(df['suma_horas'] > 24.01).sum()}")

# 4. Limpieza final: eliminamos las columnas temporales (dejamos los minutos
↳originales para no alterar la data madre)
df = df.drop(columns=['suma_horas', 'exercise_hours'])

print("¡Ajuste de 24 horas completado con base proporcional!")

```

```

Alumnos que reportaron imposiblemente más de 24 hrs al día: 47
Alumnos excedidos tras la limpieza: 0
¡Ajuste de 24 horas completado con base proporcional!

```


0.0.11 12. Verificación de Limpieza Completa

Confirmamos nuevamente que hemos lidiado exitosamente con todas las correcciones necesarias y la eliminación del 100% de los valores faltantes. La gráfica de “Missingno” aparece ahora completamente sólida. La base se encuentra purificada, estandarizada y óptima para el Modelamiento de Regresión No Lineal y MCO

```

[18]: msno.matrix(df)
      plt.show()
      df

```



```
[18]:
```

	student_id	age	academic_level	study_hours	self_study_hours	\
0	1	20.0	2	5.37	2.09	
1	2	16.0	1	5.85	5.04	
2	3	18.0	2	5.69	2.27	
3	4	24.0	2	2.32	1.06	
4	5	24.0	3	3.87	2.63	
...	...	...	...	...	...	
5616	5617	21.0	3	4.16	0.00	
5617	5618	25.0	3	4.53	2.48	
5618	5619	20.0	3	4.53	2.48	
5619	5620	20.0	3	4.53	2.48	
5620	5621	18.0	3	3.96	0.98	

	online_classes_hours	social_media_hours	gaming_hours	sleep_hours	\
0	1.85	3.66	2.32	7.730	
1	1.87	3.60	2.79	6.110	
2	0.00	2.93	3.94	7.110	
3	2.30	4.34	2.37	8.540	
4	2.54	3.71	1.30	7.690	
...	...	...	...	...	
5616	1.27	4.01	3.41	8.070	
5617	2.01	5.18	1.50	7.015	
5618	2.01	2.99	1.50	7.015	
5619	2.01	3.52	1.50	7.015	
5620	1.77	4.35	2.22	6.570	

	screen_time_hours	...	upcoming_deadline	internet_quality	\
0	5.68	...	0.0	3	
1	8.96	...	0.0	3	

2	11.02	...	0.0	2
3	8.73	...	1.0	1
4	9.60	...	1.0	1
...	...	...	...	...
5616	10.80	...	1.0	1
5617	6.95	...	1.0	3
5618	6.95	...	1.0	3
5619	6.95	...	1.0	3
5620	8.89	...	0.0	1

	mental_health_score	focus_index	burnout_level	productivity_score \
0	3.0	19.01	31.77	42.59
1	10.0	42.10	45.89	67.15
2	5.0	21.93	37.07	37.68
3	3.0	13.47	43.63	12.83
4	2.0	19.95	56.62	18.53
...	...	...	...	...
5616	7.0	21.78	48.07	43.06
5617	8.0	29.38	45.65	42.52
5618	5.0	29.38	45.65	36.92
5619	5.0	29.38	45.65	36.92
5620	3.0	16.28	36.62	21.36

	exam_score	rindio_examen	gender_male	gender_other
0	25.08	1	1	0
1	37.83	1	0	0
2	18.66	1	0	0
3	1.00	0	1	0
4	7.78	1	0	0
...	...	...	...	...
5616	17.15	1	1	0
5617	21.06	1	0	0
5618	NaN	0	1	0
5619	NaN	0	1	0
5620	2.81	1	1	0

[5621 rows x 23 columns]

0.1 Parte 2

```
[19]: # Versión mínima para ver la df
print("INFORMACIÓN DEL dfFRAME:")
print(f"Dimensiones: {df.shape}")
print(f"\nColumnas: {list(df.columns)}")
print(f"\nTipos: {df.dtypes}")
print(f"\nPrimeras 3 filas: {df.head(3)}")
```

```

print(f"\nEstadísticas numéricas:\n{df.describe()}")
print(f"\nValores nulos:\n{df.isnull().sum()}")
print(f"\nValores únicos en categóricas:")
for col in df.select_dtypes(include=['object']).columns:
    print(f"{col}: {df[col].unique()[:5]}")
print(df.dtypes)

# Seleccionar solo las variables numéricas para la correlación
numeric_df = df.select_dtypes(include=['float64', 'int64'])

# Calcular la matriz de correlación
corr_matrix = numeric_df.corr()

# Generar el mapa de calor
plt.figure(figsize=(14, 12))
sns.heatmap(corr_matrix, annot=True, fmt=".2f", cmap='coolwarm', center=0)
plt.title('Matriz de Correlación de Variables')
plt.show()

```

INFORMACIÓN DEL dfFRAME:

Dimensiones: (5621, 23)

Columnas: ['student_id', 'age', 'academic_level', 'study_hours', 'self_study_hours', 'online_classes_hours', 'social_media_hours', 'gaming_hours', 'sleep_hours', 'screen_time_hours', 'exercise_minutes', 'caffeine_intake_mg', 'part_time_job', 'upcoming_deadline', 'internet_quality', 'mental_health_score', 'focus_index', 'burnout_level', 'productivity_score', 'exam_score', 'rindio_examen', 'gender_male', 'gender_other']

Tipos:

student_id	int64
age	float64
academic_level	int64
study_hours	float64
self_study_hours	float64
online_classes_hours	float64
social_media_hours	float64
gaming_hours	float64
sleep_hours	float64
screen_time_hours	float64
exercise_minutes	float64
caffeine_intake_mg	float64
part_time_job	int64
upcoming_deadline	float64
internet_quality	int64
mental_health_score	float64
focus_index	float64
burnout_level	float64


```

productivity_score    float64
exam_score            float64
rindio_examen         int64
gender_male           int64
gender_other          int64
dtype: object

```

Primeras 3 filas:

```

    student_id  age  academic_level  study_hours  self_study_hours  \
0             1  20.0              2         5.37             2.09
1             2  16.0              1         5.85             5.04
2             3  18.0              2         5.69             2.27

    online_classes_hours  social_media_hours  gaming_hours  sleep_hours  \
0                   1.85                3.66          2.32          7.73
1                   1.87                3.60          2.79          6.11
2                   0.00                2.93          3.94          7.11

    screen_time_hours  ...  upcoming_deadline  internet_quality  \
0                   5.68  ...                0.0                3
1                   8.96  ...                0.0                3
2                  11.02  ...                0.0                2

    mental_health_score  focus_index  burnout_level  productivity_score  \
0                   3.0          19.01          31.77          42.59
1                  10.0          42.10          45.89          67.15
2                   5.0          21.93          37.07          37.68

    exam_score  rindio_examen  gender_male  gender_other
0         25.08              1            1            0
1         37.83              1            0            0
2         18.66              1            0            0

```

[3 rows x 23 columns]

Estadísticas numéricas:

```

    student_id  age  academic_level  study_hours  \
count  5621.000000  5621.000000    5621.000000  5621.000000
mean    2811.000000   20.451699     2.116883    4.532898
std    1622.787263    2.710404     0.834766    1.712212
min       1.000000   16.000000     1.000000    0.000000
25%    1406.000000   18.000000     1.000000    3.420000
50%    2811.000000   20.000000     2.000000    4.530000
75%    4216.000000   23.000000     3.000000    5.600000
max     5621.000000   25.000000     3.000000    9.510000

    self_study_hours  online_classes_hours  social_media_hours  \
count           5621.000000           5621.000000           5621.000000

```

mean	2.480400	2.012017	2.999441
std	1.105977	0.921525	1.380653
min	0.000000	0.000000	0.000000
25%	1.780000	1.420000	2.140000
50%	2.480000	2.010000	2.990000
75%	3.160000	2.580000	3.880000
max	7.410000	6.000000	8.280000

	gaming_hours	sleep_hours	screen_time_hours	...	upcoming_deadline \
count	5621.000000	5621.000000	5621.000000	...	5621.000000
mean	1.562057	7.019449	6.976017	...	0.564846
std	1.044096	1.098393	2.349919	...	0.495821
min	0.000000	4.000000	1.000000	...	0.000000
25%	0.800000	6.340000	5.480000	...	0.000000
50%	1.500000	7.015000	6.950000	...	1.000000
75%	2.230000	7.720000	8.480000	...	1.000000
max	5.580000	10.000000	15.300000	...	1.000000

	internet_quality	mental_health_score	focus_index	burnout_level \
count	5621.000000	5621.000000	5621.000000	5621.000000
mean	2.106209	5.454901	29.387205	45.635302
std	0.830640	2.700989	9.416268	13.318149
min	1.000000	1.000000	1.000000	1.000000
25%	1.000000	3.000000	23.580000	37.270000
50%	2.000000	5.000000	29.380000	45.650000
75%	3.000000	8.000000	35.270000	53.670000
max	3.000000	10.000000	63.480000	97.580000

	productivity_score	exam_score	rindio_examen	gender_male \
count	5621.000000	4912.000000	5621.000000	5621.000000
mean	37.26886	18.840542	0.795766	0.492973
std	15.85772	12.119456	0.403177	0.499995
min	1.000000	1.000000	0.000000	0.000000
25%	26.99000	9.410000	1.000000	0.000000
50%	36.92000	17.990000	1.000000	0.000000
75%	47.60000	27.410000	1.000000	1.000000
max	98.02000	64.090000	1.000000	1.000000

	gender_other
count	5621.000000
mean	0.119018
std	0.323838
min	0.000000
25%	0.000000
50%	0.000000
75%	0.000000
max	1.000000

[8 rows x 23 columns]

Valores nulos:

student_id	0
age	0
academic_level	0
study_hours	0
self_study_hours	0
online_classes_hours	0
social_media_hours	0
gaming_hours	0
sleep_hours	0
screen_time_hours	0
exercise_minutes	0
caffeine_intake_mg	0
part_time_job	0
upcoming_deadline	0
internet_quality	0
mental_health_score	0
focus_index	0
burnout_level	0
productivity_score	0
exam_score	709
rindio_examen	0
gender_male	0
gender_other	0
dtype:	int64


Valores únicos en categóricas:

student_id	int64
age	float64
academic_level	int64
study_hours	float64
self_study_hours	float64
online_classes_hours	float64
social_media_hours	float64
gaming_hours	float64
sleep_hours	float64
screen_time_hours	float64
exercise_minutes	float64
caffeine_intake_mg	float64
part_time_job	int64
upcoming_deadline	float64
internet_quality	int64
mental_health_score	float64
focus_index	float64
burnout_level	float64
productivity_score	float64

```

exam_score                float64
rindio_examen             int64
gender_male               int64
gender_other              int64
dtype: object

```



0.2 Pregunta 2: Modelo de Probabilidad Lineal (MCO)

Para responder a esta pregunta, utilizaremos un **Modelo de Probabilidad Lineal estimando por Mínimos Cuadrados Ordinarios (MCO)**. Dado que nuestra variable dependiente (**rindio_examen**) es binaria (1 o 0), el estimador OLS nos permitirá encontrar el cambio porcentual en la probabilidad empírica de ocurrencia.

Estrategia de Selección de Variables: En lugar de elegir variables de manera arbitraria, utilizaremos un enfoque empírico de “Eliminación Hacia Atrás”. 1. Primero, excluirémos variables restrictivas como **student_id** (pues no tiene valor probabilístico) y **exam_score** (ya que la ocu-

rencia del examen depende directamente de poseer una nota superior a 1.0). 2. Ejecutaremos un **Modelo Completo** exploratorio con el resto de las variables para auditar si existe multicolinealidad y para observar el Valor-P inicial de todos los regresores juntos.

```
[20]: # 1. Definimos las Variables Excluidas (Nuestra X no debe tener la nota, ni el ID, ni el target)
columns_a_excluir = ['student_id', 'exam_score', 'rindio_examen']

# 2. Separamos Y (target) y X (variables independientes)
Y = df['rindio_examen']
X = df.drop(columns=columns_a_excluir)

# 3. MCO requiere explícitamente agregarle una constante (El intercepto Beta_0)
X_con_constante = sm.add_constant(X)

# 4. Ajustamos el Modelo Mínimos Cuadrados Ordinarios (OLS)
modelo_mco_completo = sm.OLS(Y, X_con_constante).fit()

# 5. Imprimimos el resumen estadístico
print(modelo_mco_completo.summary())
```

```

                                OLS Regression Results
=====
Dep. Variable:          rindio_examen    R-squared:                0.206
Model:                  OLS              Adj. R-squared:          0.203
Method:                 Least Squares    F-statistic:              72.76
Date:                   Tue, 21 Apr 2026  Prob (F-statistic):      2.65e-262
Time:                   16:21:06         Log-Likelihood:           -2220.2
No. Observations:       5621            AIC:                     4482.
Df Residuals:           5600            BIC:                     4622.
Df Model:                20
Covariance Type:        nonrobust
=====
=====
                                coef      std err          t      P>|t|      [0.025
0.975]
-----
-----
const                0.6721      0.076      8.878      0.000      0.524
0.821
age                  0.0019      0.002      1.097      0.273     -0.002
0.005
academic_level     -0.0646      0.006     -11.081      0.000     -0.076
-0.053
study_hours         0.0070      0.005      1.372      0.170     -0.003
0.017
self_study_hours   -0.0012      0.005     -0.259      0.796     -0.010
0.008

```

online_classes_hours	0.0002	0.005	0.032	0.975	-0.010
0.010					
social_media_hours	-0.0013	0.004	-0.327	0.744	-0.009
0.006					
gaming_hours	-0.0004	0.005	-0.092	0.926	-0.010
0.009					
sleep_hours	0.0183	0.006	2.991	0.003	0.006
0.030					
screen_time_hours	-0.0086	0.002	-3.532	0.000	-0.013
-0.004					
exercise_minutes	4.45e-05	0.000	0.362	0.717	-0.000
0.000					
caffeine_intake_mg	-7.856e-05	3.78e-05	-2.078	0.038	-0.000
-4.43e-06					
part_time_job	0.0625	0.012	5.235	0.000	0.039
0.086					
upcoming_deadline	-0.1371	0.014	-10.051	0.000	-0.164
-0.110					
internet_quality	-0.0482	0.006	-8.253	0.000	-0.060
-0.037					
mental_health_score	0.0071	0.003	2.151	0.032	0.001
0.014					
focus_index	0.0041	0.001	4.217	0.000	0.002
0.006					
burnout_level	0.0003	0.001	0.452	0.651	-0.001
0.002					
productivity_score	0.0045	0.001	5.622	0.000	0.003
0.006					
gender_male	-0.0964	0.010	-9.275	0.000	-0.117
-0.076					
gender_other	0.0062	0.016	0.388	0.698	-0.025
0.037					

Omnibus:	634.406	Durbin-Watson:	2.044
Prob(Omnibus):	0.000	Jarque-Bera (JB):	873.855
Skew:	-0.964	Prob(JB):	1.76e-190
Kurtosis:	2.893	Cond. No.	4.75e+03

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 4.75e+03. This might indicate that there are strong multicollinearity or other numerical problems.

Como pudimos evidenciar en el resumen del modelo inicial exploratorio, la inclusión masiva de variables de tiempo (como horas totales, redes sociales, estudio, etc.) causó **alta multicolinealidad** en el modelo. Esto infló la varianza y anuló la eficiencia explicativa de muchas variables.

Para asegurar la robustez de nuestra predicción y solucionar el sobreajuste matemático, procedimos a remover sistemáticamente todas las variables que **fallaron la prueba de significancia estadística** (es decir, aquellas cuyo Valor-P superaba el 0.05). Variables como edad, ingesta de cafeína, y horas específicas de estudio online fueron eliminadas. A continuación, recalcularemos nuestro **Modelo Final** libre de ruido estadístico.

```
[21]: # 1. Definimos las Variables Excluidas (Nuestra X no debe tener la nota, ni el ID, ni el target)
      <math>\rightarrow</math>ID, ni el target)
columnas_a_excluir_final = [
    'student_id', 'exam_score', 'rindio_examen', # Las prohibidas de siempre
    'age', 'study_hours', 'self_study_hours', 'online_classes_hours', # Las que
    <math>\rightarrow</math>no importaron
    'social_media_hours', 'gaming_hours', 'exercise_minutes',
    'burnout_level', 'gender_other'
]

# 2. Separamos Y (target) y X (variables independientes)
Y = df['rindio_examen']
X = df.drop(columns=columnas_a_excluir)

# Recalculamos
X_final = df.drop(columns=columnas_a_excluir_final)
X_con_constante_final = sm.add_constant(X_final)
modelo_mco_final = sm.OLS(Y, X_con_constante_final).fit()
print(modelo_mco_final.summary())
```

```

                                OLS Regression Results
=====
Dep. Variable:          rindio_examen    R-squared:                0.206
Model:                  OLS              Adj. R-squared:         0.204
Method:                 Least Squares    F-statistic:            132.0
Date:                  Tue, 21 Apr 2026  Prob (F-statistic):       1.84e-270
Time:                  16:21:06          Log-Likelihood:         -2222.2
No. Observations:      5621             AIC:                  4468.
Df Residuals:          5609             BIC:                  4548.
Df Model:              11
Covariance Type:       nonrobust
=====
=====
                                coef      std err          t      P>|t|      [0.025
0.975]
-----
const                0.7543         0.042     17.978     0.000         0.672
0.837
academic_level      -0.0650         0.006    -11.171     0.000        -0.076
-0.054
sleep_hours          0.0143         0.004      3.210     0.001         0.006

```

```

0.023
screen_time_hours      -0.0075      0.002      -3.646      0.000      -0.012
-0.003
caffeine_intake_mg     -6.845e-05   3.55e-05   -1.928      0.054      -0.000
1.15e-06
part_time_job          0.0680      0.010      6.859      0.000      0.049
0.087
upcoming_deadline      -0.1298      0.010     -12.954      0.000      -0.149
-0.110
internet_quality       -0.0484      0.006      -8.301      0.000      -0.060
-0.037
mental_health_score     0.0041      0.002      1.753      0.080      -0.000
0.009
focus_index           0.0043      0.001      5.277      0.000      0.003
0.006
productivity_score      0.0052      0.001     10.036      0.000      0.004
0.006
gender_male            -0.0983      0.010     -10.159      0.000      -0.117
-0.079
=====
Omnibus:                634.969   Durbin-Watson:                2.045
Prob(Omnibus):          0.000   Jarque-Bera (JB):            874.797
Skew:                   -0.965   Prob(JB):                    1.10e-190
Kurtosis:               2.892   Cond. No.                     2.54e+03
=====

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 2.54e+03. This might indicate that there are strong multicollinearity or other numerical problems.

```

[22]: # 1. Definimos las Variables Excluidas (Nuestra X no debe tener la nota, ni el ID, ni el target)
      ↪ID, ni el target)
columnas_a_excluir_final = [
    'student_id', 'exam_score', 'rindio_examen', # Las prohibidas de siempre
    'age', 'study_hours', 'self_study_hours', 'online_classes_hours', # Las que
    ↪no importaron
    'social_media_hours', 'gaming_hours', 'exercise_minutes',
    'burnout_level', 'gender_other', 'caffeine_intake_mg'
]

# 2. Separamos Y (target) y X (variables independientes)
Y = df['rindio_examen']
X = df.drop(columns=columnas_a_excluir)

# Recalculamos

```



```
X_final = df.drop(columns=columnas_a_excluir_final)
X_con_constante_final = sm.add_constant(X_final)
modelo_mco_final = sm.OLS(Y, X_con_constante_final).fit()
print(modelo_mco_final.summary())
```

OLS Regression Results

```
=====
Dep. Variable:          rindio_examen    R-squared:                0.205
Model:                  OLS             Adj. R-squared:          0.204
Method:                 Least Squares    F-statistic:             144.8
Date:                   Tue, 21 Apr 2026  Prob (F-statistic):       9.45e-271
Time:                   16:21:06         Log-Likelihood:          -2224.1
No. Observations:      5621             AIC:                    4470.
Df Residuals:          5610             BIC:                    4543.
Df Model:               10
Covariance Type:       nonrobust
=====
```

```
=====
               coef      std err          t      P>|t|      [0.025
0.975]
-----
const          0.7358      0.041     18.012      0.000      0.656
0.816
academic_level -0.0651      0.006    -11.183      0.000     -0.077
-0.054
sleep_hours     0.0143      0.004      3.203      0.001      0.006
0.023
screen_time_hours -0.0074      0.002     -3.575      0.000     -0.011
-0.003
part_time_job    0.0685      0.010      6.901      0.000      0.049
0.088
upcoming_deadline -0.1293      0.010    -12.907      0.000     -0.149
-0.110
internet_quality -0.0484      0.006     -8.291      0.000     -0.060
-0.037
mental_health_score 0.0038      0.002      1.656      0.098     -0.001
0.008
focus_index     0.0042      0.001      5.193      0.000      0.003
0.006
productivity_score 0.0053      0.001     10.246      0.000      0.004
0.006
gender_male     -0.0980      0.010    -10.125      0.000     -0.117
-0.079
=====
```

```
Omnibus:          636.900    Durbin-Watson:           2.046
Prob(Omnibus):    0.000    Jarque-Bera (JB):        878.528
Skew:             -0.967    Prob(JB):                1.70e-191
```

Kurtosis: 2.896 Cond. No. 443.

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
[23]: # 1. Definimos las Variables Excluidas (Nuestra X no debe tener la nota, ni el ID, ni el target)
columnas_a_excluir_final = [
    'student_id', 'exam_score', 'rindio_examen', # Las prohibidas de siempre
    'age', 'study_hours', 'self_study_hours', 'online_classes_hours', # Las que no importaron
    'social_media_hours', 'gaming_hours', 'exercise_minutes',
    'burnout_level', 'gender_other', 'caffeine_intake_mg', 'mental_health_score'
]

# 2. Separamos Y (target) y X (variables independientes)
Y = df['rindio_examen']
X = df.drop(columns=columnas_a_excluir)

# Recalculamos
X_final = df.drop(columns=columnas_a_excluir_final)
X_con_constante_final = sm.add_constant(X_final)
#modelo_mco_final = sm.OLS(Y, X_con_constante_final).fit()
modelo_mco_final = sm.OLS(Y, X_con_constante_final).fit(cov_type='HC1')
print(modelo_mco_final.summary())
```

OLS Regression Results

```
=====
Dep. Variable:          rindio_examen    R-squared:                0.205
Model:                  OLS              Adj. R-squared:          0.203
Method:                 Least Squares    F-statistic:             145.5
Date:                   Tue, 21 Apr 2026  Prob (F-statistic):       7.64e-248
Time:                   16:21:06         Log-Likelihood:          -2225.5
No. Observations:      5621             AIC:                   4471.
Df Residuals:          5611             BIC:                   4537.
Df Model:               9
Covariance Type:       HC1
=====
=====
```

	coef	std err	z	P> z	[0.025
0.975]					
const	0.7423	0.040	18.579	0.000	0.664
0.821					
academic_level	-0.0652	0.006	-11.228	0.000	-0.077

-0.054					
sleep_hours	0.0134	0.004	3.215	0.001	0.005
0.022					
screen_time_hours	-0.0071	0.002	-3.840	0.000	-0.011
-0.003					
part_time_job	0.0699	0.010	7.330	0.000	0.051
0.089					
upcoming_deadline	-0.1282	0.009	-13.632	0.000	-0.147
-0.110					
internet_quality	-0.0484	0.006	-8.343	0.000	-0.060
-0.037					
focus_index	0.0044	0.001	5.311	0.000	0.003
0.006					
productivity_score	0.0056	0.001	11.211	0.000	0.005
0.007					
gender_male	-0.0987	0.010	-10.378	0.000	-0.117
-0.080					
=====					
Omnibus:	638.625	Durbin-Watson:		2.046	
Prob(Omnibus):	0.000	Jarque-Bera (JB):		881.886	
Skew:	-0.969	Prob(JB):		3.17e-192	
Kurtosis:	2.900	Cond. No.		439.	
=====					

Notes:

[1] Standard Errors are heteroscedasticity robust (HC1)

0.2.1 Interpretación de Resultados del MCO

Al depurar las variables irrelevantes, nuestro **Modelo Final** quedó completamente libre de la alerta de multicolinealidad, y **el 100% de las variables seleccionadas resultaron altísimamente significativas** (Valores-P < 0.005). Los coeficientes (β) en el MCO se interpretan como el aumento o caída directa porcentual en la capacidad de predecir que un estudiante rinda la prueba matemáticamente.

Interpretación de las variables clave:

- Factores Demográficos y de Desempeño:**
 - * **gender_male:** Ser estudiante de género masculino se asocia con una reducción empírica del **9.8%** en la probabilidad de rendir el examen respecto al grupo base. Por el contrario, las mujeres tienen un **9.8%** más altas probabilidades de presentarse a rendir en examen que los hombres.
 - * **academic_level:** Por cada nivel académico superior (High School -> Undergraduate -> Postgraduate), la probabilidad cae un **6.5%**.
 - * **focus_index** y **productivity_score:** Muestran una relación positiva; un mayor índice de enfoque y productividad empuja la asistencia al examen de forma significativa y segura (+0.44% y +0.56% por cada punto en sus escalas respectivas).
- Factores Externos e Infraestructura:**
 - * **upcoming_deadline:** Poseer fechas de entrega inminentes penaliza drásticamente la asistencia, restándole un gigantesco **12.8%** a la probabilidad de que el alumno rinda la prueba principal.
 - * **part_time_job:** Contra todo pronóstico intuitivo, poseer trabajo part-time *incrementa* estructuralmente la probabilidad asociativa de rendir el examen en

casi un **7.0%**. * **internet_quality**: Las mejoras en la calidad del internet se asocian negativamente con el modelo ($\sim -4.8\%$), una potencial paradoja a investigar. 3. **Hábitos Personales**: * **sleep_hours**: Las horas de descanso demostraron ser un predictor vital positivo, sumando un **1.3%** extra a la probabilidad de rendición por cada hora adicional de sueño diario. * Por el contrario, cada hora de pantallas generalizadas (**screen_time_hours**) le resta estructuralmente un **0.7%** a la predicción estadística de presentarse a la prueba.

La depuración empírica y los altos estadísticos t de cada coeficiente confirman que este modelo depurado es un excelente pronosticador lineal.

0.3 Pregunta 3: Modelo Probit

A continuación estimaremos un modelo **Probit**. Calcularemos los **efectos marginales** para poder interpretar y comparar los resultados tal como lo hicimos en el Modelo Lineal (MCO).

```
[24]: # 1. Ajustar el modelo Probit utilizando nuestras variables depuradas
      ↪(X_con_constante_final)
      #modelo_probit = sm.Probit(Y, X_con_constante_final).fit()
      modelo_probit = sm.Probit(Y, X_con_constante_final).fit(cov_type='HC1')
      # 2. Imprimir el resumen puro del modelo (pseudo R-squared etc)
      print(modelo_probit.summary())

      # 3. Calcular Efectos Marginales (interpretables finalmente como cambios en
      ↪propabilidad)
      margeff_probit = modelo_probit.get_margeff()
      print("\n--- EFECTOS MARGINALES DEL MODELO PROBIT ---")
      print(margeff_probit.summary())
```

Optimization terminated successfully.

Current function value: 0.384791

Iterations 6

Probit Regression Results

```
=====
Dep. Variable:          rindio_examen    No. Observations:          5621
Model:                  Probit           Df Residuals:              5611
Method:                 MLE             Df Model:                  9
Date:                   Tue, 21 Apr 2026  Pseudo R-squ.:              0.2399
Time:                   16:21:06          Log-Likelihood:             -2162.9
converged:              True             LL-Null:                  -2845.4
Covariance Type:       HC1              LLR p-value:              2.734e-288
=====
=====
              coef      std err          z      P>|z|      [0.025
0.975]
-----
const          0.6182      0.179      3.446      0.001      0.267
```

```

0.970
academic_level      -0.3049      0.028      -10.768      0.000      -0.360
-0.249
sleep_hours         0.0775      0.021       3.759      0.000      0.037
0.118
screen_time_hours   -0.0349      0.009      -3.780      0.000      -0.053
-0.017
part_time_job       0.3282      0.045       7.217      0.000      0.239
0.417
upcoming_deadline   -0.6085      0.049     -12.448      0.000      -0.704
-0.513
internet_quality    -0.2133      0.027      -7.785      0.000      -0.267
-0.160
focus_index        0.0219      0.004       5.653      0.000      0.014
0.030
productivity_score   0.0287      0.002     11.601      0.000      0.024
0.034
gender_male         -0.4419      0.044      -9.960      0.000      -0.529
-0.355
=====
=====

```

--- EFECTOS MARGINALES DEL MODELO PROBIT ---

Probit Marginal Effects

```

=====
Dep. Variable:      rindio_examen
Method:             dydx
At:                 overall
=====
=====

```

	dy/dx	std err	z	P> z	[0.025
0.975]					

academic_level	-0.0662	0.006	-11.333	0.000	-0.078
-0.055					
sleep_hours	0.0168	0.004	3.775	0.000	0.008
0.026					
screen_time_hours	-0.0076	0.002	-3.801	0.000	-0.011
-0.004					
part_time_job	0.0713	0.010	7.300	0.000	0.052
0.090					
upcoming_deadline	-0.1321	0.010	-13.399	0.000	-0.151
-0.113					
internet_quality	-0.0463	0.006	-8.041	0.000	-0.058
-0.035					
focus_index	0.0048	0.001	5.735	0.000	0.003
0.006					

productivity_score	0.0062	0.001	12.272	0.000	0.005
gender_male	-0.0959	0.009	-10.341	0.000	-0.114

0.007
-0.078

=====

=====

0.3.1 Interpretación de Resultados del Modelo Probit (Efectos Marginales)

A diferencia del MCO, los coeficientes arrojados inicialmente por el modelo Probit no expresan una magnitud interpretable directamente, por la no-linealidad del modelo. Es por esto que observamos los **Efectos Marginales** (dy/dx), los cuales sí nos permiten cuantificar el cambio exacto en la probabilidad de que `rindio_examen = 1`.

Basado en el resumen de los efectos marginales robustos, extraemos las siguientes conclusiones manteniendo constantes todos los demás factores:

1. **Fuerte penalización por carga externa:** Tener un examen o entrega inminente (`upcoming_deadline`) muestra el mayor impacto marginal negativo del modelo, disminuyendo la probabilidad de rendir el examen en un **12.8%**. Siendo completamente significativo mediante Valor-P.
2. **Hábitos de Cuidado Personal:** El modelo detecta que por cada nivel extra en horas de sueño diario (`sleep_hours`), la probabilidad de rendición aumenta en casi un **1.3%**, probando la relación predictiva entre el descanso apropiado y la presentación efectiva a rendir exámenes. En contraparte, los recursos destinados a conexión (`internet_quality`) extrañamente reportan que caer a niveles bajos reduce marginalmente la asistencia en un **4.8%**.
3. **Productividad contra Expectativas:** El sorpresivo regresor del rol laboral (`part_time_job`) dictamina firmemente que el hecho empírico de trabajar a tiempo parcial empuja la probabilidad de rendir el examen hacia arriba en un **7.0%** en relación con un estudiante que no trabaja.

0.4 Pregunta 4: Modelo Logit

Ahora estimaremos el modelo **Logit**. Este funciona de manera bastante similar al Probit pero usando una distribución logística, conocida por manejar eventos con extremas propabilidades un poco mejor.

```
[25]: # 1. Ajustar modelo Logit
#modelo_logit = sm.Logit(Y, X_con_constante_final).fit()
modelo_logit = sm.Logit(Y, X_con_constante_final).fit(cov_type='HC1')
# 2. Resumen del Logit
print(modelo_logit.summary())

# 3. Efectos Marginales
margeff_logit = modelo_logit.get_margeff()
print("\n--- EFECTOS MARGINALES DEL MODELO LOGIT ---")
print(margeff_logit.summary())
```

Optimization terminated successfully.

Current function value: 0.382173

Iterations 7

Logit Regression Results

```
=====
Dep. Variable:          rindio_examen    No. Observations:          5621
Model:                  Logit           Df Residuals:              5611
Method:                 MLE             Df Model:                  9
Date:                  Tue, 21 Apr 2026   Pseudo R-squ.:             0.2450
Time:                  16:21:06          Log-Likelihood:            -2148.2
converged:              True             LL-Null:                   -2845.4
Covariance Type:        HC1             LLR p-value:               1.196e-294
=====
```

```
=====
                                coef    std err          z      P>|z|      [0.025
0.975]
-----
const                1.1581      0.321      3.607      0.000      0.529
1.787
academic_level      -0.5700      0.051     -11.232      0.000     -0.669
-0.471
sleep_hours         0.1395      0.036      3.840      0.000      0.068
0.211
screen_time_hours   -0.0634      0.016     -3.876      0.000     -0.095
-0.031
part_time_job       0.5737      0.080      7.213      0.000      0.418
0.730
upcoming_deadline   -1.1495      0.089     -12.976      0.000     -1.323
-0.976
internet_quality    -0.4093      0.049     -8.318      0.000     -0.506
-0.313
focus_index        0.0405      0.007      5.863      0.000      0.027
0.054
productivity_score   0.0531      0.004     12.049      0.000      0.044
0.062
gender_male         -0.8122      0.079     -10.320      0.000     -0.966
-0.658
=====
```

--- EFECTOS MARGINALES DEL MODELO LOGIT ---

Logit Marginal Effects

```
=====
Dep. Variable:          rindio_examen
Method:                 dydx
At:                     overall
=====
```

	dy/dx	std err	z	P> z	[0.025
0.975]					

academic_level	-0.0695	0.006	-11.857	0.000	-0.081
-0.058					
sleep_hours	0.0170	0.004	3.853	0.000	0.008
0.026					
screen_time_hours	-0.0077	0.002	-3.895	0.000	-0.012
-0.004					
part_time_job	0.0700	0.010	7.297	0.000	0.051
0.089					
upcoming_deadline	-0.1402	0.010	-13.999	0.000	-0.160
-0.121					
internet_quality	-0.0499	0.006	-8.643	0.000	-0.061
-0.039					
focus_index	0.0049	0.001	5.937	0.000	0.003
0.007					
productivity_score	0.0065	0.001	12.631	0.000	0.005
0.007					
gender_male	-0.0991	0.009	-10.778	0.000	-0.117
-0.081					
=====					
=====					

0.4.1 Interpretación de Resultados del Modelo Logit (Efectos Marginales)

Procedemos a interpretar sus Efectos Marginales para comparar la probabilidad de éxito empírico:

1. **Variables de Naturaleza Académica y Psicológica:** La estructura de `academic_level` reporta mediante su efecto marginal (dy/dx) que, al ascender un peldaño en complejidad educacional estandarizada, la probabilidad predictiva de que el estudiante se ausente se estira y debilita progresivamente un **6.5%**.
2. **Características Demográficas:** El factor dicotómico aislado de ser hombre (`gender_male`) reduce marginalmente en un **9.8%** las chances de presentarse formalmente en un examen.
3. **Consistencia de la Distribución:** Al mapear las varianzas, todo el set demuestra ser matemáticamente robusto con Valores-P iguales a 0. Las probabilidades predictivas que nos entregan estos efectos marginales trazan resultados prácticamente iguales a los derivados del cálculo de una distribución estricta de modelo Normal (Probit), confirmando que esta muestra es absolutamente apta y confiable para resoluciones teóricas que eviten las fallas lineales del MCO estándar.

0.4.2 Pregunta 5: Análisis Comparativo y Selección del Modelo Óptimo

```
[26]: from stargazer.stargazer import Stargazer
      from IPython.core.display import HTML

      stargazer = Stargazer([modelo_mco_final, modelo_logit, modelo_probit])

      stargazer.title("Comparación de Modelos: OLS, Logit y Probit")
      stargazer.custom_columns(["Modelo OLS", "Modelo Logit", "Modelo Probit"], [1, 1, 1])
      stargazer.add_custom_notes(["Nota: Todos los modelos utilizan errores estándar robustos (HC1)."])

      HTML(stargazer.render_html())
```

[26]: <IPython.core.display.HTML object>

```
[27]: # Para comparar los modelos, podemos usar el AIC (Akaike Information Criterion) y el BIC (Bayesian Information Criterion) que son medidas de la calidad del modelo penalizadas por el número de parámetros. El modelo con el menor AIC y BIC es generalmente considerado el mejor.
      print("Comparativa de Modelos:")
      print(f"Modelo OLS: AIC = {modelo_mco_final.aic:.2f}, BIC = {modelo_mco_final.bic:.2f}")
      print(f"Modelo Logit: AIC = {modelo_logit.aic:.2f}, BIC = {modelo_logit.bic:.2f}")
      print(f"Modelo Probit: AIC = {modelo_probit.aic:.2f}, BIC = {modelo_probit.bic:.2f}")
```

Comparativa de Modelos:

Modelo OLS: AIC = 4470.91, BIC = 4537.25

Modelo Logit: AIC = 4316.39, BIC = 4382.73

Modelo Probit: AIC = 4345.82, BIC = 4412.17

Tras haber estimado y tabulado (vía Stargazer) los tres modelos econométricos (Mínimos Cuadrados Ordinarios, Probit y Logit) para explicar la probabilidad binomial de que un estudiante rinda su examen final, podemos realizar las siguientes observaciones sobre su comportamiento:

1. Comparativa de Resultados y Explicación de sus Diferencias: Al contrastar los modelos, se puede apreciar que los **Efectos Marginales** (dy/dx) extraídos de los modelos de respuesta binaria no-lineales (Probit y Logit) convergen hacia magnitudes predictivas *casi idénticas* a las ponderaciones (β) estimadas linealmente a través de MCO. Por ejemplo, enfrentar una entrega inminente (`upcoming_deadline`) se asocia a una penalización aproximadamente del **12.8%** a lo largo de los 3 modelos. Las ligeras diferencias que persisten entre los modelos nacen estrictamente de sus supuestos funcionales: * El **MCO** asume una asociación recta e infinita, ignorando la cota probabilística e ignorando la heterocedasticidad inherente en respuestas de 0 y 1. * El **Probit** fuerza a los errores a distribuirse siguiendo la campana Gaussiana Estándar Acumulada. * El **Logit** modela sobre una Función de Distribución Logística, dotando a su “campana” estadística de colas levemente más pesadas, permitiéndole lidiar con observaciones probabilísticas extremas de manera

diferencial frente al Probit.

2. Decisión del Modelo Más Adecuado: el modelo Logit representa la herramienta estadísticamente óptima para responder a nuestra pregunta de investigación.

El MCO debe ser descartado del análisis binomial puesto que las rectas lineales permiten la proyección de “probabilidades” imposibles (mayores al 100% o menores al 0%). A la hora de coronar al Logit sobre el Probit, **la decisión es confirmada en su totalidad por nuestros estadísticos de ajuste cruzado (Akaike y Bayesiano)**: el MCO poseía el peor ajuste ($AIC = 4470.91$, $BIC = 4537.25$), pero al iterar, el clasificador Logístico demostró ser la red empírica mejor ensamblada para la base de datos, entregando la cuota de error más baja ($AIC = 4316.39$, $BIC = 4382.73$), batiendo con ventaja a sus dos contrapartes. Del mismo modo, el Pseudo ² más grande es del modelo logit, explicando el mayor porcentaje de la realidad del ¿Por qué? los individuos de la muestra deciden asistir o no al examen.

3. Variables Robustas a la Especificación: Toda variable que sobrevivió al filtro iterativo demostró ser **robusta a la especificación econométrica**. Identificadores empíricos como mantener un trabajo *part-time* (`part_time_job`), cursar grados formales jerárquicamente mayores (`academic_level`), y el tiempo de descanso (`sleep_hours`), no sufrieron alteraciones ni en su signo direccional, ni en el peso de su rigor estadístico ($P > |z| \approx 0.000$) independiente de si se probaban en funciones MCO, Logit o Probit.

0.4.3 Pregunta 6

```
[28]: # 1. Filtramos SÓLO los estudiantes que SÍ rindieron el examen
df_rindieron = df[df['rindio_examen'] == 1].copy()

# 2. Tu nuevo Target (Y) es la NOTA, no la asistencia
Y_poisson = df_rindieron['exam_score']

[29]: columnas_a_excluir_poisson = [
    'student_id', 'exam_score', 'rindio_examen',
    'age', 'study_hours', 'self_study_hours', 'online_classes_hours',
    'social_media_hours', 'gaming_hours', 'exercise_minutes',
    'burnout_level', 'gender_other', 'caffeine_intake_mg', 'mental_health_score'
]
X_poisson = df_rindieron.drop(columns=columnas_a_excluir_poisson)
X_con_constante_poisson = sm.add_constant(X_poisson)

modelo_poisson = sm.Poisson(Y_poisson, X_con_constante_poisson).
    ↪fit(cov_type='HC1')
print(modelo_poisson.summary())
```

Optimization terminated successfully.

Current function value: 3.297099

Iterations 5

Poisson Regression Results

=====

```

Dep. Variable:          exam_score  No. Observations:          4473
Model:                  Poisson     Df Residuals:              4463
Method:                  MLE        Df Model:                  9
Date:                   Tue, 21 Apr 2026  Pseudo R-squ.:          0.4111
Time:                   16:21:06      Log-Likelihood:          -14748.
converged:              True        LL-Null:                  -25045.
Covariance Type:        HC1         LLR p-value:              0.000
=====

```

```

=====
=====
              coef      std err          z      P>|z|      [0.025
0.975]
-----
-----
const          1.4899      0.038     39.338      0.000      1.416
1.564
academic_level  0.0024      0.005      0.457      0.648     -0.008
0.013
sleep_hours     0.0495      0.004     13.440      0.000      0.042
0.057
screen_time_hours -0.0159      0.002     -9.031      0.000     -0.019
-0.012
part_time_job   -0.0873      0.009     -9.905      0.000     -0.105
-0.070
upcoming_deadline -0.1345      0.009    -15.341      0.000     -0.152
-0.117
internet_quality  0.0017      0.005      0.315      0.753     -0.009
0.012
focus_index     0.0123      0.001     16.903      0.000      0.011
0.014
productivity_score 0.0227      0.000     50.204      0.000      0.022
0.024
gender_male      0.0081      0.009      0.938      0.348     -0.009
0.025
=====
=====

```

```

[30]: columnas_a_excluir_poisson = [
        'student_id', 'exam_score', 'rindio_examen',
        'age', 'study_hours', 'self_study_hours', 'online_classes_hours',
        'social_media_hours', 'gaming_hours', 'exercise_minutes',
        'burnout_level', 'gender_other', 'caffeine_intake_mg', 'mental_health_score',
        'academic_level', 'internet_quality', 'gender_male'
    ]
X_poisson = df_rindieron.drop(columns=columnas_a_excluir_poisson)
X_con_constante_poisson = sm.add_constant(X_poisson)

```

```

modelo_poisson = sm.Poisson(Y_poisson, X_con_constante_poisson).
    ↪fit(cov_type='HC1')
print(modelo_poisson.summary())

```

Optimization terminated successfully.

Current function value: 3.297330

Iterations 5

Poisson Regression Results

```

=====
Dep. Variable:          exam_score  No. Observations:          4473
Model:                  Poisson    Df Residuals:              4466
Method:                  MLE       Df Model:                  6
Date:                   Tue, 21 Apr 2026  Pseudo R-squ.:          0.4111
Time:                   16:21:07    Log-Likelihood:          -14749.
converged:              True       LL-Null:                 -25045.
Covariance Type:        HC1       LLR p-value:             0.000
=====
=====
              coef      std err          z      P>|z|      [0.025
0.975]
-----
-----
const          1.5032      0.033     45.186     0.000      1.438
1.568
sleep_hours     0.0493      0.004     13.444     0.000      0.042
0.056
screen_time_hours -0.0159      0.002     -9.062     0.000     -0.019
-0.012
part_time_job   -0.0873      0.009     -9.898     0.000     -0.105
-0.070
upcoming_deadline -0.1339      0.009    -15.255     0.000     -0.151
-0.117
focus_index     0.0123      0.001     16.907     0.000      0.011
0.014
productivity_score 0.0227      0.000     50.149     0.000      0.022
0.024
=====
=====

```

Interpretación de la estimación de Poisson (Pregunta 6):

- Variables Significativas:** En el modelo Poisson las variables de `sleep_hours`, `screen_time_hours`, `part_time_job`, `upcoming_deadline`, `focus_index` y `productivity_score` son fuertemente significativas (Valor-P < 0.05).
- Interpretación de los coeficientes:**
 - `sleep_hours` ($\beta = 0.0493$): Por cada hora adicional de sueño, la nota esperada aumenta en aproximadamente un 4.93%.
 - `focus_index` ($\beta = 0.0123$) y `productivity_score` ($\beta = 0.0227$): Por cada incremento

en un punto del índice de concentración o de la productividad, la nota esperada aumenta alrededor de un 1.23% y 2.27%, respectivamente.

- **screen_time_hours** ($\beta = -0.0159$): Cada hora adicional de pantalla disminuye el puntaje final esperado en un 1.59%.
- **part_time_job** ($\beta = -0.0873$): Los estudiantes que trabajan medio tiempo tienden a tener una nota un 8.73% más baja frente al resto de estudiantes.
- **upcoming_deadline** ($\beta = -0.1339$): Aquellos sometidos a fechas límite que se aproximan, obtienen notas un 13.39% menores.

3. **Evaluación global:** El Pseudo R-cuadrado es notablemente alto (0.4111), indicando un buen nivel explicativo de nuestro conjunto acotado de variables predictoras en la nota de los alumnos.

0.4.4 Pregunta 7

Determine si existe sobre dispersion en la data y posible valor optimo de alpha para un modelo Binomial Negativa.

```
[31]: # 1. Obtenemos las predicciones (lambda / mu) del modelo Poisson ajustado
      ↪ previamente
mu = modelo_poisson.predict()

# 2. Calculamos la variable dependiente auxiliar descrita para el test de
      ↪ sobredispersión
aux_olsr = ((Y_poisson - mu)**2 - Y_poisson) / mu

# 3. Corremos una regresión lineal (MCO/OLS) auxiliar, sin constante, usando mu
      ↪ como única variable explicativa
modelo_auxiliar = sm.OLS(aux_olsr, mu).fit()
print("--- RESULTADOS TEST DE SOBREDISPERSIÓN ---")
print(modelo_auxiliar.summary())

# El estimador de alpha será la pendiente del modelo anterior.
alpha_estimado = modelo_auxiliar.params.iloc[0]
p_value_alpha = modelo_auxiliar.pvalues.iloc[0]

print("\n=====")
if p_value_alpha < 0.05 and alpha_estimado > 0:
    print(f"Existe EVIDENCIA ESTADÍSTICA firme de sobredispersión
      ↪ (Valor-P={p_value_alpha:.4f} < 0.05).")
    print(f"Se procederá a utilizar el valor óptimo (alpha estimado) =
      ↪ {alpha_estimado:.4f} para el modelo Binomial Negativo.")
else:
    print("No hay evidencia de sobredispersión en la distribución, o la
      ↪ sobredispersión no es significativa (Poisson es suficiente).")
```

--- RESULTADOS TEST DE SOBREDISPERSIÓN ---

OLS Regression Results

=====

Dep. Variable: exam_score R-squared (uncentered): 0.044
 Model: OLS Adj. R-squared (uncentered): 0.044
 Method: Least Squares F-statistic: 207.5
 Date: Tue, 21 Apr 2026 Prob (F-statistic): 4.98e-46
 Time: 16:21:07 Log-Likelihood: -11169.
 No. Observations: 4473 AIC: 2.234e+04
 Df Residuals: 4472 BIC: 2.235e+04
 Df Model: 1
 Covariance Type: nonrobust

=====

	coef	std err	t	P> t	[0.025	0.975]
x1	0.0274	0.002	14.406	0.000	0.024	0.031

=====

Omnibus: 4769.744 Durbin-Watson: 2.010
 Prob(Omnibus): 0.000 Jarque-Bera (JB): 564216.230
 Skew: 5.161 Prob(JB): 0.00
 Kurtosis: 57.044 Cond. No. 1.00

=====

Notes:

- [1] R^2 is computed without centering (uncentered) since the model does not contain a constant.
 [2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

=====

Existe EVIDENCIA ESTADÍSTICA firme de sobredispersión (Valor-P=0.0000 < 0.05).
 Se procederá a utilizar el valor óptimo (alpha estimado) = 0.0274 para el modelo Binomial Negativo.

Conclusión del Test de Sobredispersión:

Para verificar si la dispersión de nuestros datos es mayor a la media proyectada, ejecutamos la regresión lineal auxiliar recomendada.

- **Estimación de Alpha (α):** Obtuvimos un coeficiente de pendiente de 0.0274. Al ser positivamente mayor a cero, confirma que la varianza penaliza el modelo. El valor-P del

coeficiente es de 0.000 ($p < 0.05$), por lo que es estadísticamente significativa.

Decisión: Existe evidencia estadística firme que demuestra **sobredispersión** en nuestra variable de interés. Debido a esto, el modelo de Poisson es insuficiente y procederemos a utilizar un **Modelo Binomial Negativo**, inyectándole nuestro valor óptimo de $\alpha = 0.0274$ para recalibrar correctamente los errores estándar.

0.4.5 Pregunta 8

Usando la información anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

```
[32]: # Utilizando las mismas variables robustas que hallamos en la pregunta 6 para el
      ↪ modelo final
      # X_con_constante_poisson ya contiene la constante y las variables dependientes
      ↪ más significativas (ya depuradas).

      # Instanciamos y ajustamos el modelo GLM indicando una familia Binomial Negativa
      ↪ y pasándole el alpha calculado.
modelo_nbinom = sm.GLM(
    Y_poisson,
    X_con_constante_poisson,
    family=sm.families.NegativeBinomial(alpha=alpha_estimado)
).fit(cov_type='HC1')

print(modelo_nbinom.summary())
```

```

Generalized Linear Model Regression Results
=====
Dep. Variable:          exam_score    No. Observations:          4473
Model:                  GLM           Df Residuals:              4466
Model Family:          NegativeBinomial Df Model:                  6
Link Function:          Log           Scale:                    1.0000
Method:                 IRLS          Log-Likelihood:          -14380.
Date:                  Tue, 21 Apr 2026 Deviance:                  5941.3
Time:                  16:21:07        Pearson chi2:             5.48e+03
No. Iterations:         6              Pseudo R-squ. (CS):       0.9503
Covariance Type:        HC1
=====
=====
              coef      std err          z      P>|z|      [0.025
0.975]
-----
const          1.4107      0.035     40.425     0.000      1.342
1.479
sleep_hours     0.0531      0.004     13.817     0.000      0.046

```

0.061					
screen_time_hours	-0.0175	0.002	-9.623	0.000	-0.021
-0.014					
part_time_job	-0.0942	0.009	-10.270	0.000	-0.112
-0.076					
upcoming_deadline	-0.1454	0.009	-15.839	0.000	-0.163
-0.127					
focus_index	0.0134	0.001	17.617	0.000	0.012
0.015					
productivity_score	0.0238	0.000	51.081	0.000	0.023
0.025					
=====					
=====					

Interpretación de Resultados - Regresión Binomial Negativa:

Al estimar el modelo insertando el parámetro de sobredispersión hallado previamente, podemos concluir lo siguiente:

1. **Variables Significativas:** Las seis variables incorporadas (`sleep_hours`, `screen_time_hours`, `part_time_job`, `upcoming_deadline`, `focus_index` y `productivity_score`) continúan siendo fuertemente significativas, arrojando valores p prácticamente nulos ($P > |z| = 0.000$).
2. **Impacto Exponencial (Coeficientes):** Debido a que el modelo ocupa una función de enlace logarítmica (Log-Link), los coeficientes representan cambios multiplicativos porcentuales ($\approx 100 \cdot \beta\%$).
 - **Efectos Positivos:** Mejorar las horas de sueño (+5.31% por hora adicional), el foco mental (+1.34% por punto) y la productividad en clase (+2.38% por punto) aumentan de forma consistente la nota esperada del alumno.
 - **Efectos Negativos:** Inversamente, agentes estresores o de desconcentración penalizan la nota considerablemente. Aquellos que poseen entregas próximas bajan su rendimiento esperado en un monumental 14.5%, tener trabajo de medio tiempo lo reduce en 9.4%, y cada hora adicional gastada en pantallas lo baja un 1.75%.

Conclusión: Las variables robustas se ratifican. Al corregirse los márgenes de error a través del relajamiento de la varianza (Binomial Negativo), ganamos certeza respecto a que estos factores y sus magnitudes representan determinantes fiables sobre las calificaciones de los estudiantes.

0.4.6 Respuesta a Pregunta 9: Análisis Comparativo

1. Diferencias entre los modelos (Poisson vs. Binomial Negativo): Los coeficientes estimados en ambos modelos son muy similares numéricamente, pero difieren en sus **Errores Estándar**. Esto sucede porque el modelo Poisson asume erróneamente que la media y la varianza son iguales (equidispersión). El modelo Binomial Negativo, en cambio, añade el parámetro α para corregir la sobredispersión, volviendo los errores estándar ligeramente más flexibles y reales.

2. Modelo más adecuado: El modelo idóneo es el **Binomial Negativo**. En la Pregunta 7 se demostró de manera estadísticamente significativa (valor- $P = 0.000$) la existencia de un parámetro

$\alpha > 0$ ($\alpha = 0.0274$). Usar el modelo Poisson en una muestra con sobredispersión habría infravalorado la varianza e inflado la significancia de las variables, generando conclusiones erróneas.

3. Variables robustas a la especificación: Aquellas variables que conservaron consistentemente su significancia estadística ($P < 0.05$) a lo largo de todos los modelos (desde MCO hasta Binomial Negativo) demostraron ser estrictamente robustas. Estas fueron: * **Positivas:** Horas de sueño (`sleep_hours`), y los índices cognitivos (`focus_index`, `productivity_score`). * **Negativas:** Tiempo de pantalla (`screen_time_hours`), trabajar a tiempo parcial (`part_time_job`) y tener entregas inminentes (`upcoming_deadline`).