

Tarea_1_Godoy_Xavier

April 28, 2026

1 Tarea 1 Xavier Godoy Cerda - 2022451939

2 Pregunta 1

```
[1]: #Importamos librerías
import pandas as pd
import numpy as np
import statsmodels.api as sm
import statsmodels.formula.api as smf
import matplotlib.pyplot as plt
import seaborn as sns
```

```
%matplotlib inline
sns.set_theme(style="whitegrid")
```

```
[2]: #Leemos la base de datos e identificamos la naturaleza de las variables
df = pd.read_csv("student_productivity.csv")
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 5621 entries, 0 to 5620
```

```
Data columns (total 22 columns):
```

#	Column	Non-Null Count	Dtype
0	student_id	5621 non-null	int64
1	age	4973 non-null	float64
2	gender	5063 non-null	object
3	academic_level	4991 non-null	object
4	study_hours	5047 non-null	float64
5	self_study_hours	4954 non-null	float64
6	online_classes_hours	4939 non-null	float64
7	social_media_hours	4965 non-null	float64
8	gaming_hours	4965 non-null	float64
9	sleep_hours	5068 non-null	float64
10	screen_time_hours	5035 non-null	float64
11	exercise_minutes	5022 non-null	object
12	caffeine_intake_mg	5021 non-null	float64
13	part_time_job	4918 non-null	object

```

14  upcoming_deadline      4904 non-null   float64
15  internet_quality       5098 non-null   object
16  mental_health_score    4946 non-null   float64
17  drug_use               1518 non-null   float64
18  focus_index            4988 non-null   float64
19  burnout_level          4905 non-null   float64
20  productivity_score      4983 non-null   float64
21  exam_score             4912 non-null   float64
dtypes: float64(16), int64(1), object(5)
memory usage: 966.2+ KB
None

```

En base a la información que nos entrega .info podemos ver las variables que tienen valores numéricos enteros, decimales y los que tienen texto, los cuales deberemos ajustar.

Otra dato importante a destacar de este primer análisis a las variables (junto con un previo análisis rápido en data wrangler), es la gran cantidad de datos faltantes en la variable “drug_use”, por lo cual la descartaremos desde ya para evitar perder demasiados datos en nuestro posterior modelo.

```

[3]: #Crea una columna nueva en el data frame que corresponde a
#una variable que indica si rinde el examen con un 1 o un 0 si no
df2 = df.copy()
df2["rinde_examen"] = np.where((df2["exam_score"] == 1.0) | (df2["exam_score"].
    ↪isna()), 0, 1)

print(df2["academic_level"].unique().tolist()) #se aprecia que hay problemas en
    ↪las variables con espacios extras al final
pd.crosstab(df2["academic_level"], df2["rinde_examen"], normalize="index")*100
    ↪# acá igual

#limpiar academic level

```

```

['Undergraduate', 'High School', 'Undergraduate ', 'Postgraduate', nan, 'High
School ', 'Postgraduate ']

```

```

[3]: rinde_examen      0      1
academic_level
High School      14.985380  85.014620
High School      15.000000  85.000000
Postgraduate     13.906810  86.093190
Postgraduate     14.000000  86.000000
Undergraduate    11.304348  88.695652
Undergraduate    11.290323  88.709677

```

```

[4]: #para variables numericas
df2[["study_hours", "sleep_hours", "rinde_examen"]].describe().round(1)

```

```

[4]:      study_hours  sleep_hours  rinde_examen
count      5047.0      5068.0      5621.0

```

mean	4.5	7.0	0.8
std	1.8	1.2	0.4
min	0.0	4.0	0.0
25%	3.3	6.2	1.0
50%	4.5	7.0	1.0
75%	5.8	7.8	1.0
max	11.8	10.0	1.0

```
[5]: #para variables categóricas
print(df2["gender"].value_counts())
print(df2["academic_level"].value_counts())
print(df2["part_time_job"].value_counts())
print(df2["upcoming_deadline"].value_counts())
```

```
Male      2213
Female    2181
Other      669
Name: gender, dtype: int64
Postgraduate    1395
Undergraduate   1380
High School     1368
High School      300
Postgraduate     300
Undergraduate    248
Name: academic_level, dtype: int64
No      1838
Yes     1753
yes      696
no       631
Name: part_time_job, dtype: int64
1.0     2458
0.0     2446
Name: upcoming_deadline, dtype: int64
```

```
[6]: #elimina los espacios al principio y al final de las variables categóricas
variables_categoricas = ["gender", "academic_level", "part_time_job"]
for i in variables_categoricas:
    df2[i] = df2[i].str.strip()
```

```
[7]: #limpieza part time job, cohesionamos los yes y los no en 1 y 0
df2["part_time_job"] = df2["part_time_job"].replace({
    "Yes": 1, "yes": 1,
    "No": 0, "no": 0
})
```

```
[8]: #limpieza upcoming deadline convertir en numeros enteros
df2["upcoming_deadline"] = df2["upcoming_deadline"].astype("Int64")
```


```
[9]: print(df2["gender"].value_counts())
print(df2["academic_level"].value_counts())
print(df2["part_time_job"].value_counts())
print(df2["upcoming_deadline"].value_counts())
```

```
Male      2213
Female    2181
Other      669
Name: gender, dtype: int64
Postgraduate    1695
High School     1668
Undergraduate   1628
Name: academic_level, dtype: int64
0.0     2469
1.0     2449
Name: part_time_job, dtype: int64
1      2458
0      2446
Name: upcoming_deadline, dtype: Int64
```

```
[10]: fig, axes = plt.subplots(1, 2, figsize=(10, 4))
sns.boxplot(data=df2, y='study_hours', ax=axes[0], color='skyblue')
axes[0].set_title('Distribución de Horas de Estudio')

sns.boxplot(data=df2, y='sleep_hours', ax=axes[1], color='lightgreen')
axes[1].set_title('Distribución de Horas de Sueño')

plt.show()
```



```
[11]: #imputación de nulos con mediana para variables numericas
df2["study_hours"] = df2["study_hours"].fillna(df2["study_hours"].median())
```

```

df2["sleep_hours"] = df2["sleep_hours"].fillna(df2["sleep_hours"].median())

#Dropeamos nulos de gender y academic level, ya que no son muchos y no podemos
↳ inventar con aproximaciones
df2 = df2.dropna(subset=["gender", "academic_level"])

#Eliminamos el 1% más extremo
study_hours99 = np.percentile(df2["study_hours"], 99)
sleep_hours99 = np.percentile(df2["sleep_hours"], 99)

df2 = df2[(df2["study_hours"] <= study_hours99) &
          (df2["sleep_hours"] <= sleep_hours99)]

#Creamos variables dummy para las variables categóricas que no son binarias
df2 = pd.get_dummies(df2, columns=["gender", "academic_level"],
↳ drop_first=True, dtype=int)

```

3 Pregunta 2

```

[12]: #creo dataframe con las variables que me importan
cmo = [
    "rinde_examen",
    "study_hours",
    "sleep_hours",
    "part_time_job",
    "upcoming_deadline",
    "gender_Male",
    "gender_Other",
    "academic_level_Postgraduate",
    "academic_level_Undergraduate"
]
df_modelos = df2[cmo].copy()

df_modelos = df_modelos.astype(float) #generaba error ya que upcoming deadline
↳ es Int64

ecuacion = """
rinde_examen ~ study_hours + sleep_hours + part_time_job + upcoming_deadline +
↳ gender_Male + gender_Other + academic_level_Postgraduate +
academic_level_Undergraduate
"""

modelo_mco = smf.ols(formula=ecuacion, data=df_modelos).fit(cov_type="HC1")
print(modelo_mco.summary())

```

OLS Regression Results

```

=====
Dep. Variable:          rinde_examen    R-squared:                0.095
Model:                  OLS             Adj. R-squared:           0.094
Method:                 Least Squares   F-statistic:             40.33
Date:                  Mon, 20 Apr 2026 Prob (F-statistic):       1.33e-62
Time:                  16:29:35         Log-Likelihood:          -960.85
No. Observations:      4457            AIC:                    1940.
Df Residuals:          4448            BIC:                    1997.
Df Model:               8
Covariance Type:       HC1
=====

```

```

=====
                                coef    std err          z      P>|z|
-----
[0.025    0.975]
-----
Intercept                    0.4434      0.037     11.873     0.000
0.370    0.517
study_hours                   0.0462      0.003     15.755     0.000
0.040    0.052
sleep_hours                   0.0375      0.004      8.684     0.000
0.029    0.046
part_time_job                -0.0434      0.009     -4.833     0.000
-0.061   -0.026
upcoming_deadline            -0.0494      0.009     -5.475     0.000
-0.067   -0.032
gender_Male                   0.0072      0.010      0.754     0.451
-0.012    0.026
gender_Other                  2.506e-05      0.015      0.002     0.999
-0.029    0.029
academic_level_Postgraduate   0.0213      0.011      1.880     0.060
-0.001    0.044
academic_level_Undergraduate  0.0344      0.011      3.122     0.002
0.013    0.056
=====

```

```

=====
Omnibus:                    1770.087   Durbin-Watson:             2.025
Prob(Omnibus):              0.000     Jarque-Bera (JB):          5468.213
Skew:                      -2.127     Prob(JB):                  0.00
Kurtosis:                   6.370     Cond. No.:                 62.8
=====

```

Notes:

[1] Standard Errors are heteroscedasticity robust (HC1)

3.1 Conclusiones modelo de regresión lineal simple (MCO)

Nuestro modelo MCO con errores estándar robusto arroja un estadístico F de $1.33e-62$, lo cual verifica que las variables explicativas seleccionadas influyen en conjunto en la probabilidad de que un alumno se presente a rendir el examen. Además, posee un R-cuadrado de 0.095, esto significa que logra explicar un 9.5% de la varianza de la variable a analizar (si un estudiante rinde o no el examen).

3.1.1 Variables significativas

Podemos notar que estas variables poseen un valor- $p < 0.05$

- “study_hours”: Tiene un valor- p de 0.000, con un coeficiente de 0.0462 que indica que por cada hora de estudio extra, hay un aumento de 4.62 puntos porcentuales en la probabilidad de que un estudiante rinda el examen.
- “sleep_hours”: Tiene un valor- p de 0.000, con un coeficiente de 0.0375 que indica que por cada hora de sueño extra, hay un aumento de 3.75 puntos porcentuales en la probabilidad de rendir el examen por parte de un estudiante.

Podíamos esperar resultados de este estilo para estas variables, ya que, son hábitos que generalmente traen resultados positivos ante un examen.

- “part_time_job”: Tiene un valor- p de 0.000, con un coeficiente de -0.0434 que indica que si un estudiante posee un trabajo part time, hay una disminución de 4.34 puntos porcentuales en la probabilidad de rendir el examen en comparación al que no tiene un trabajo part time.

Esto tiene sentido y relación a las variables antes vistas, ya que, probablemente invierten menos tiempo en estudiar, en dormir o ambas, lo cual puede generar inseguridad de los conocimientos y/o falta de preparación.

- “upcoming_deadline”: Tiene un valor- p de 0.000, con un coeficiente de -0.0494 que indica que si un estudiante tiene otras responsabilidades que requieren una entrega o asistencia a rendir otro examen, hay una disminución de 4.94 puntos porcentuales en la probabilidad de rendir el examen por parte de un estudiante.

Esto se puede deber a razones de priorización de otras tareas, o mala organización del tiempo, que puede llevar a la falta de preparación para un examen, por lo que al tener otras responsabilidades, hay más probabilidad que decida no dar el examen, que si solo tiene este examen.

- “academic_level_Undergraduate” Tiene un valor- p de 0.002, con un coeficiente de 0.0344 que indica que un estudiante universitario de pregrado tiene 3.44 puntos porcentuales más de probabilidad de rendir el examen en comparación a los estudiantes de “high school” o colegio.

Esto probablemente se debe a la flexibilización que tienen los colegios por sobre universidades a la hora de realizar exámenes atrasados, ya que, en el colegio a diferencia de la universidad se realizan estos, en horarios de clase o extraprogramáticos, los cuales el alumno puede acordar previamente con el profesor al tener mayor cercanía, quizás por que se ven un año entero a diferencia de la universidad que los profesores se ven con los alumnos en una asignatura 2 horas a la semana.

3.1.2 Variables no significativas

Podemos notar que estas variables poseen un valor- $p > 0.05$

- “gender_Male” y “gender_Other”: Estas son variables dummy que toman como base el género femenino, por lo tanto podemos notar la diferencia de probabilidad entre estas y nuestra variable base, pero considerando que tiene un valor-p de 0.451, independiente del coeficiente que tenga, este no es concluyente para nuestro análisis, por lo tanto, podemos considerar en principio que el género del estudiante no afecta significativamente en la probabilidad que tiene este de rendir un examen.
- “Academic_level_Postgraduate”: Esta variable a diferencia de “academic_level_Undergraduate” no es significativa por muy poco, posee un valor-p de 0.06, pero al criterio de 5% de error permitido la consideramos no significativa, sin embargo, esta indicaba que un estudiante de una especialización post graduado tiene 2.13 puntos porcentuales más de probabilidad de rendir un examen que un estudiante de colegio.

4 Pregunta 3

```
[15]: # Usamos exactamente la misma ecuación y datos que en el MCO para el modelo
      ↪PROBIT
modelo_probit = smf.probit(formula=ecuacion, data=df_modelos).fit()
print(modelo_probit.summary())

# Calculamos e imprimimos los efectos marginales (dy/dx)
efectos_marginales_probit = modelo_probit.get_margeff()
print(efectos_marginales_probit.summary())
```

Optimization terminated successfully.

Current function value: 0.302708

Iterations 6

Probit Regression Results					
=====					
Dep. Variable:	rinde_examen	No. Observations:	4457		
Model:	Probit	Df Residuals:	4448		
Method:	MLE	Df Model:	8		
Date:	Mon, 20 Apr 2026	Pseudo R-squ.:	0.1377		
Time:	20:50:59	Log-Likelihood:	-1349.2		
converged:	True	LL-Null:	-1564.7		
Covariance Type:	nonrobust	LLR p-value:	4.414e-88		
=====					
=====					
		coef	std err	z	P> z
[0.025	0.975]				

Intercept		-1.1693	0.192	-6.084	0.000
-1.546	-0.793				
study_hours		0.2640	0.016	16.261	0.000
0.232	0.296				
sleep_hours		0.2200	0.024	9.103	0.000
0.173	0.267				

part_time_job	-0.2411	0.054	-4.471	0.000
-0.347 -0.135				
upcoming_deadline	-0.2853	0.054	-5.275	0.000
-0.391 -0.179				
gender_Male	0.0223	0.058	0.386	0.699
-0.091 0.135				
gender_Other	-0.0196	0.084	-0.235	0.814
-0.184 0.144				
academic_level_Postgraduate	0.1022	0.064	1.592	0.111
-0.024 0.228				
academic_level_Undergraduate	0.1851	0.066	2.788	0.005
0.055 0.315				
=====				
=====				
Probit Marginal Effects				
=====				
Dep. Variable:	rinde_examen			
Method:	dydx			
At:	overall			
=====				
=====				
		dy/dx	std err	z P> z
[0.025 0.975]				

study_hours	0.0439	0.003	16.443	0.000
0.039 0.049				
sleep_hours	0.0366	0.004	9.135	0.000
0.029 0.044				
part_time_job	-0.0401	0.009	-4.472	0.000
-0.058 -0.023				
upcoming_deadline	-0.0475	0.009	-5.280	0.000
-0.065 -0.030				
gender_Male	0.0037	0.010	0.386	0.699
-0.015 0.023				
gender_Other	-0.0033	0.014	-0.235	0.814
-0.031 0.024				
academic_level_Postgraduate	0.0170	0.011	1.593	0.111
-0.004 0.038				
academic_level_Undergraduate	0.0308	0.011	2.789	0.005
0.009 0.052				
=====				
=====				

Los resultados del modelo Probit son altamente consistentes con nuestra estimación por MCO y a su vez sumamente significativos debido al LLR p-value de 4.414e-88.

Ambos modelos identifican a las horas de estudio, sueño, poseer empleo part time y tener entregas pendientes como los principales motores de decisión del alumnado.

Podemos notar que los valores de los coeficientes en el modelo MCO y las magnitudes de los efectos marginales difieren muy poco en términos de puntos porcentuales, esto demuestra que nuestros resultados son robustos.

No obstante el Probit nos entrega mayor certeza teórica que el MCO, al forzar una distribución normal, evitamos la posibilidad de predecir probabilidades fuera del rango real.

Añadir que podemos concluir finalmente que “academic_level_Postgraduate” no es una variable significativa, por su valor-p de 0.111 a diferencia de antes (0.06), por lo que podemos concluir que no hay una diferencia concluyente entre los estudiantes de posgrado y los de colegio o highschool.

5 Pregunta 4

```
[16]: # Estimamos el modelo Logit usando la misma ecuación
modelo_logit = smf.logit(formula=ecuacion, data=df_modelos).fit()
print(modelo_logit.summary())

# Calculamos e imprimimos los efectos marginales (dy/dx)
efectos_marginales_logit = modelo_logit.get_margeff()
print(efectos_marginales_logit.summary())
```

Optimization terminated successfully.

Current function value: 0.301106

Iterations 7

```

                                Logit Regression Results
=====
Dep. Variable:                rinde_examen    No. Observations:                4457
Model:                        Logit          Df Residuals:                4448
Method:                       MLE           Df Model:                  8
Date:                         Mon, 20 Apr 2026   Pseudo R-squ.:                0.1423
Time:                         21:14:16         Log-Likelihood:               -1342.0
converged:                    True            LL-Null:                     -1564.7
Covariance Type:              nonrobust        LLR p-value:                  3.858e-91
=====
=====
                                coef    std err          z      P>|z|
-----
[0.025    0.975]
-----
Intercept                    -2.5019    0.361      -6.935    0.000
-3.209    -1.795
study_hours                   0.5152    0.031     16.379    0.000
0.454    0.577
sleep_hours                   0.4296    0.046     9.288    0.000
0.339    0.520
part_time_job                 -0.4894    0.103     -4.771    0.000
-0.690    -0.288
upcoming_deadline            -0.5629    0.103     -5.466    0.000

```

-0.765	-0.361				
gender_Male		0.0502	0.109	0.461	0.645
-0.163	0.264				
gender_Other		-0.0287	0.157	-0.183	0.855
-0.336	0.279				
academic_level_Postgraduate		0.1871	0.120	1.561	0.119
-0.048	0.422				
academic_level_Undergraduate		0.3696	0.126	2.933	0.003
0.123	0.617				
=====					
=====					
Logit Marginal Effects					
=====					
Dep. Variable:	rinde_examen				
Method:	dydx				
At:	overall				
=====					
=====					
		dy/dx	std err	z	P> z
[0.025	0.975]				

study_hours		0.0452	0.003	16.757	0.000
0.040	0.051				
sleep_hours		0.0377	0.004	9.359	0.000
0.030	0.046				
part_time_job		-0.0430	0.009	-4.781	0.000
-0.061	-0.025				
upcoming_deadline		-0.0494	0.009	-5.482	0.000
-0.067	-0.032				
gender_Male		0.0044	0.010	0.461	0.645
-0.014	0.023				
gender_Other		-0.0025	0.014	-0.183	0.855
-0.030	0.025				
academic_level_Postgraduate		0.0164	0.011	1.561	0.119
-0.004	0.037				
academic_level_Undergraduate		0.0325	0.011	2.935	0.003
0.011	0.054				
=====					
=====					

Nuevamente debido al LLR p-value de 3.858e-91 es altamente significativo el modelo explicativo.

Podemos notar que son robustamente significativas algunas variables ya que por ejemplo en el modelo MCO el coeficiente y en el modelo Logit el efecto marginal de la variable “upcoming_deadline” posee el mismo valor (-0.0494).

El modelo Logit asume una distribución logística de los errores y corrobora lo hallado en el MCO y el Probit, tal que todas las variables significativas mantuvieron sus niveles de significancia, con

valores de coeficientes y efectos marginales muy similares.

6 Pregunta 5

La conclusión general es que los resultados son empíricamente consistentes. Los tres modelos van en la misma dirección y con magnitudes muy similares. Estudiar y dormir suma puntos porcentuales; tener trabajo y deadlines los resta. El género no influye de ninguna manera y el nivel académico solo influye significativamente en los estudiantes de pregrado.

La diferencia entre los valores de los distintos modelos no es significativa, pero esta se debe a que el MCO simplemente dibuja una línea recta infinita, por lo que asume que el efecto de una hora extra de sueño es la misma para el que duerme 1 hora y para el que duerme 12, y eso no es así. El modelo Probit y Logit solucionan esto curvando la línea en forma de S, obligando a la predicción a estar siempre entre 0 y 1. La pequeña diferencia entre estos últimos modelos mencionados es que la campana logística en el modelo Logit tiene colas un poco más gordas, por lo que trata los extremos con más indulgencia.

El modelo más adecuado sería el Logit debido a que su distribución de colas más pesadas provee mayor robustez general ante casos extremos impredecibles de los estudiantes que el modelo Probit.

Las variables que resultaron ser robustamente significativas fueron: “study_hours”, “sleep_hours”, “part_time_job”, “upcoming_deadline” y “academic_level_Undergraduate”, ya que se mantuvieron significativas en todos los modelos de regresión.

7 Pregunta 6

```
[19]: # Filtramos los datos

df_poisson = df2[df2["rinde_examen"] == 1].copy()

# Seleccionamos las columnas y las pasamos a float para evitar errores
columnas_poisson = [
    "exam_score",
    "study_hours", "sleep_hours", "part_time_job", "upcoming_deadline",
    "gender_Male", "gender_Other", "academic_level_Postgraduate",
    ↪ "academic_level_Undergraduate"
]
df_poisson = df_poisson[columnas_poisson].astype(float)

ecuacion_poisson = """
exam_score ~ study_hours + sleep_hours + part_time_job + upcoming_deadline +
    ↪ gender_Male + gender_Other + academic_level_Postgraduate +
    ↪ academic_level_Undergraduate
"""

# Estimamos el modelo Poisson
modelo_poisson = smf.poisson(formula=ecuacion_poisson, data=df_poisson).fit()
print(modelo_poisson.summary())
```

```

# Generamos las predicciones matemáticas (Lambda).
# comprobar sobredispersión después.
df_poisson['ppredictions'] = modelo_poisson.predict(df_poisson).astype(float)

# Extraemos los coeficientes originales del modelo
coeficientes_poisson = modelo_poisson.params

# Creamos un DataFrame para mostrar los resultados de forma ordenada
# Calculamos e^coef y también el porcentaje exacto de cambio
tabla_interpretacion = pd.DataFrame({
    'Coef. Original': coeficientes_poisson,
    'Factor Exponencial (e^coef)': np.exp(coeficientes_poisson),
    'Cambio Porcentual Exacto (%)': (np.exp(coeficientes_poisson) - 1) * 100
})

# Imprimimos el resultado redondeado a 2 decimales para que sea legible
print("--- Interpretación Real de Coeficientes Poisson sobre la Nota Final ---")
print(tabla_interpretacion.round(2))

```

Optimization terminated successfully.

Current function value: 4.623167

Iterations 5

Poisson Regression Results

```

=====
Dep. Variable:          exam_score  No. Observations:          3957
Model:                  Poisson     Df Residuals:              3948
Method:                  MLE        Df Model:                  8
Date:                   Mon, 20 Apr 2026  Pseudo R-squ.:          0.1695
Time:                   22:58:28      Log-Likelihood:          -18294.
converged:              True         LL-Null:                -22028.
Covariance Type:        nonrobust     LLR p-value:             0.000
=====
=====

```

		coef	std err	z	P> z
[0.025	0.975]				

Intercept		1.6205	0.027	59.625	0.000
1.567	1.674				
study_hours		0.1485	0.002	70.065	0.000
0.144	0.153				
sleep_hours		0.1195	0.003	37.381	0.000
0.113	0.126				
part_time_job		-0.1484	0.007	-20.898	0.000
-0.162	-0.134				
upcoming_deadline		-0.2308	0.007	-32.370	0.000
-0.245	-0.217				

gender_Male	-0.0115	0.008	-1.528	0.126
-0.026	0.003			
gender_Other	-0.0136	0.011	-1.201	0.230
-0.036	0.009			
academic_level_Postgraduate	0.0192	0.009	2.218	0.027
0.002	0.036			
academic_level_Undergraduate	-0.0041	0.009	-0.471	0.638
-0.021	0.013			

=====

=====

--- Interpretación Real de Coeficientes Poisson sobre la Nota Final ---

	Coef. Original	Factor Exponencial (e^{coef}) \
Intercept	1.62	5.06
study_hours	0.15	1.16
sleep_hours	0.12	1.13
part_time_job	-0.15	0.86
upcoming_deadline	-0.23	0.79
gender_Male	-0.01	0.99
gender_Other	-0.01	0.99
academic_level_Postgraduate	0.02	1.02
academic_level_Undergraduate	-0.00	1.00

	Cambio Porcentual Exacto (%)
Intercept	405.54
study_hours	16.01
sleep_hours	12.70
part_time_job	-13.79
upcoming_deadline	-20.61
gender_Male	-1.15
gender_Other	-1.35
academic_level_Postgraduate	1.94
academic_level_Undergraduate	-0.41

Después de aplicar la función exponencial a los coeficientes que nos entrega el modelo Poisson, obtenemos realmente la magnitud de las variaciones. Las cuales curiosamente aumentan bastante al haber cambiado nuestra variable dependiente (“exam_score”).

Recaltar que seguimos con las mismas variables significativas a diferencia de una. “academic_level_Undergraduate” era una variable significativa en nuestros anteriores modelos, pero ahora no, a diferencia de “academic_level_Postgraduate” que ahora si es significativa, con un coeficiente no muy grande pero significativo.

Podemos notar que por cada hora de sueño extra, la calificación aumenta un 16.01%, una hora extra de sueño aumenta un 12.7%, tener trabajo part time disminuye un 13.79% las calificaciones en comparación al que no tiene trabajo, tener una entrega pendiente con fecha límite disminuye drásticamente la calificación en un 20.61% en comparación al que solo tiene que rendir este examen y la nueva variable significativa dentro de este modelo; los estudiantes de posgrado tienen un 1.94% de calificaciones superiores en comparación a los estudiantes de colegio o highschool.

8 Pregunta 7

```
[ ]: # Eliminamos cualquier nulo para la prueba
df_poisson = df_poisson.dropna()

# Creamos la variable auxiliar basándonos en la fórmula estadística:
aux = ((df_poisson['exam_score'] - df_poisson['ppredictions'])*2 -
      df_poisson['ppredictions']) / df_poisson['ppredictions']

# Corremos la regresión OLS sin constante, sólo usando nuestra variable
      auxiliar y la predicción
prueba_alpha = sm.OLS(aux, df_poisson['ppredictions']).fit()

# Imprimimos el modelo
print(prueba_alpha.summary())
```

OLS Regression Results

```
=====
=====
Dep. Variable:                y    R-squared (uncentered):
0.236
Model:                        OLS    Adj. R-squared (uncentered):
0.236
Method:                        Least Squares    F-statistic:
1224.
Date:                          Mon, 20 Apr 2026    Prob (F-statistic):
7.20e-234
Time:                          23:25:12    Log-Likelihood:
-12364.
No. Observations:              3957    AIC:
2.473e+04
Df Residuals:                  3956    BIC:
2.474e+04
Df Model:                      1
Covariance Type:               nonrobust
=====
=====
```

	coef	std err	t	P> t	[0.025	0.975]
ppredictions	0.1439	0.004	34.985	0.000	0.136	0.152

```
=====
=====
Omnibus:                      2024.017    Durbin-Watson:                1.963
Prob(Omnibus):                 0.000    Jarque-Bera (JB):              17973.030
Skew:                          2.269    Prob(JB):                      0.00
Kurtosis:                     12.403    Cond. No.                      1.00
=====
=====
```

Notes:

[1] R^2 is computed without centering (uncentered) since the model does not

contain a constant.

[2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Si existe sobredispersión y esto se debe a que ya no estamos calculando la probabilidad de que rinda el examen o no, si no, que estamos intentando predecir la nota exacta de un estudiante, que puede no estar explicada necesariamente por estas variables, ya que no consideramos nervios, ansiedad, genética, etc, lo que hace que nuestro modelo se aleje de la predicción esperada. El posible valor óptimo para el alpha para el modelo de binomial negativa que realizaremos es de 0.1439.

9 Pregunta 8

```
[24]: alpha_optimo = 0.1439

# Estimamos el modelo Binomial Negativo.
modelo_nbin = smf.glm(
    formula=ecuacion_poisson,
    data=df_poisson,
    family=sm.families.NegativeBinomial(alpha=alpha_optimo)
).fit()

print(modelo_nbin.summary())

# Hacemos la magia del porcentaje para que lo puedas interpretar fácilmente
coeficientes_nbin = modelo_nbin.params
tabla_nbin = pd.DataFrame({
    'Coef. Original': coeficientes_nbin,
    'Cambio Porcentual Exacto (%)': (np.exp(coeficientes_nbin) - 1) * 100
})

print("\n--- Interpretación de Coeficientes: Binomial Negativo ---")
print(tabla_nbin.round(2))
```

Generalized Linear Model Regression Results

```
=====
Dep. Variable:          exam_score    No. Observations:          3957
Model:                  GLM           Df Residuals:              3948
Model Family:          NegativeBinomial    Df Model:                8
Link Function:          Log             Scale:                  1.0000
Method:                 IRLS            Log-Likelihood:         -14515.
Date:                   Wed, 22 Apr 2026    Deviance:                 5491.0
Time:                   10:41:02           Pearson chi2:             4.61e+03
No. Iterations:         5                 Pseudo R-squ. (CS):       0.3885
Covariance Type:        nonrobust
=====
=====
```

	coef	std err	z	P> z
[0.025	0.975]			

Intercept		1.5708	0.054	29.335	0.000
1.466	1.676				
study_hours		0.1526	0.004	36.129	0.000
0.144	0.161				
sleep_hours		0.1249	0.006	19.495	0.000
0.112	0.137				
part_time_job		-0.1498	0.014	-10.598	0.000
-0.177	-0.122				
upcoming_deadline		-0.2400	0.014	-16.961	0.000
-0.268	-0.212				
gender_Male		-0.0120	0.015	-0.792	0.428
-0.042	0.018				
gender_Other		-0.0076	0.023	-0.336	0.737
-0.052	0.037				
academic_level_Postgraduate		0.0127	0.017	0.734	0.463
-0.021	0.047				
academic_level_Undergraduate		-0.0083	0.017	-0.479	0.632
-0.042	0.026				
=====					
=====					

--- Interpretación de Coeficientes: Binomial Negativo ---

	Coef. Original	Cambio Porcentual Exacto (%)
Intercept	1.57	381.06
study_hours	0.15	16.48
sleep_hours	0.12	13.30
part_time_job	-0.15	-13.91
upcoming_deadline	-0.24	-21.34
gender_Male	-0.01	-1.19
gender_Other	-0.01	-0.75
academic_level_Postgraduate	0.01	1.28
academic_level_Undergraduate	-0.01	-0.83

Para responder a la predicción de calificación con la varianza corregida, utilizamos el modelo Binomial Negativo incluyendo exactamente las mismas variables del modelo base. Los resultados nos indican los impactos porcentuales en la nota de manera mucho más rigurosa:

Una hora de estudio aumenta la nota esperada en un +16.48%.

Una hora de sueño extra aumenta la nota esperada en un +13.30%.

Tener trabajo (part-time) destruye la calificación, restando un significativo -13.91%.

Tener otros entregables paralelos tiene un castigo aún mayor, restando un -21.34% a la nota final.

Además, se evidencia estadísticamente que atributos como el género o nivel académico del estudiante no tienen significancia real para predecir las calificaciones finales bajo este modelo más robusto.

10 Pregunta 9

1. Diferencias entre modelos (6, 7 y 8)

El modelo Poisson nos indicó equivocadamente que tener un nivel de posgrado era significativo frente a las notas. Esto ocurrió porque Poisson asume que la varianza de los datos es igual a su media. Sin embargo, nuestro test demostró empíricamente que existe una gran sobredispersión, es decir, el mundo real de las calificaciones es caótico y nuestra predicción tiene mayores márgenes de error. Al usar el modelo Binomial Negativo (Pregunta 8), obligamos a la matemática a considerar esa sobredispersión, se corrigieron los errores estándar, y se descubrió la verdad empírica: ser de posgrado realmente no influye en las notas.

2. ¿Cuál es el modelo más adecuado?

El ganador definitivo para este ecosistema es el Binomial Negativo. Es el único que se adapta al desorden real y humano de las calificaciones de los alumnos al controlar la sobredispersión, entregándonos conclusiones limpias, estadísticamente rigurosas y sin falsos positivos. Todo esto mientras previene matemáticamente la predicción de resultados irreales.

3. Variables robustas

A través de absolutamente todos los modelos matemáticos testeados, las únicas cuatro variables que irrefutablemente afectan el desempeño de un estudiante, sobreviviendo incluso a la inflación de errores de la Binomial Negativa, son:

- **Efectos Positivos:** “study_hours” y “sleep_hours”.
- **Efectos Negativos:** “part_time_job” y “upcoming_deadline”.

Variables demográficas como el género o nivel educacional demostraron ser irrelevantes frente a estos cuatro grandes factores de esfuerzo y manejo del tiempo.